



Institut Supérieur des Études Technologiques de Mahdia

Département : Technologies de l'Informatique

Développement des Systèmes d'Information

Rapport de Projet de Fin d'Études

HydroNova : Serre Intelligente et Automatisée

IoT • Intelligence Artificielle • Application Mobile

Élaboré par :

Wael Houidi

Ahmed Melien

Encadré par :

Mme. Afifa KHALIFA (Académique)

M. Hamza SESSI (Entreprise)

Organisme d'Accueil : MicroEdition

Période : 02 Février 2026 – 01 Juin 2026

Résumé

Ce rapport présente le projet **HydroNova**, une solution de serre intelligente et automatisée dédiée à la production de fourrage hydroponique. Conçu pour répondre à la pénurie mondiale d'eau et à l'instabilité climatique, ce système permet de réduire la consommation d'eau de près de 90% par rapport aux méthodes agricoles traditionnelles [?].

L'architecture du système repose sur une infrastructure multi-couches découplée : une couche Internet des Objets (IoT) pilotée par un contrôleur Edge Raspberry Pi assurant une régulation environnementale autonome ; une couche d'Intelligence Artificielle utilisant des réseaux de neurones convolutifs (CNN) quantifiés pour la détection en temps réel des maladies végétales ; et un noyau backend sous Spring Boot exploitant TimescaleDB pour l'ingestion de données temporelles. L'interaction utilisateur est assurée par une application mobile Flutter pour l'agriculteur et un tableau de bord React/Grafana pour la supervision administrative. Développé selon la méthodologie du Cycle en V, ce projet valide l'intégration entre le matériel embarqué et l'architecture logicielle cloud.

Mots-clés : Hydroponie, IoT, Raspberry Pi, Intelligence Artificielle, CNN, Flutter, MQTT, Cycle en V, Agriculture 4.0.

Abstract

This report presents the HydroNova project, an intelligent and automated greenhouse solution dedicated to hydroponic fodder production. Designed to address global water scarcity and climate variability, the system reduces water consumption by up to 90% compared to traditional agricultural methods.

The system architecture is built upon a decoupled multi-layered infrastructure: an Internet of Things (IoT) layer featuring a Raspberry Pi edge controller ensuring autonomous environmental regulation; an Artificial Intelligence layer utilizing quantized CNN architectures for real-time plant disease detection; and a Spring Boot backend leveraging TimescaleDB for temporal data ingestion. User interaction is provided through a Flutter mobile application for farmers and a React/Grafana dashboard for administrative supervision. Developed following the V-Model engineering methodology, this project validates the integration between embedded hardware and cloud software architecture.

Keywords: Hydroponics, IoT, Raspberry Pi, Artificial Intelligence, CNN, Flutter, MQTT, V-Model, Agriculture 4.0.

DÉDICACES

Je dédie ce travail à ma famille, les piliers silencieux de ma force. Merci pour votre soutien inconditionnel, vos immenses sacrifices et pour avoir cru en moi tout au long de mon parcours académique.

À ma mère, Moufida Mighri, la pierre angulaire de ma réussite et ma première et plus grande supportrice. Ton amour et tes prières ont été la lumière me guidant à travers chaque défi. J'espère que cet accomplissement te rend fière.

À l'âme de mon défunt oncle, Amor Mighri. Bien que tu ne sois plus parmi nous, ta mémoire reste une part indélébile de mon parcours, et ton nom reste gravé dans mon cœur comme une source d'inspiration constante.

À mes encadrants, pour leurs conseils inestimables, leur patience et l'expertise technique qui a permis de forger ce projet.

Enfin, à tous ceux qui ont contribué, ne serait-ce que par un mot gentil, à l'aboutissement de ce travail.

Wael HOUIDI

DÉDICACES

*À ma famille,
pour leur soutien inconditionnel et leurs immenses sacrifices
tout au long de mon parcours académique.*

*À mes encadrants,
pour leurs directives, leur patience et leur précieuse expertise technique.*

Ahmed MILIEN

Remerciements

Avant tout, nous rendons grâce à **Allah Le Tout-Puissant** de nous avoir accordé la santé, la patience, la volonté et le courage nécessaires pour mener à bien ce projet de fin d'études. C'est par Sa grâce et Sa bénédiction que ce travail a pu voir le jour.

Nous tenons ensuite à exprimer notre profonde et sincère gratitude à toutes les personnes qui ont contribué, de près ou de loin, à la réalisation de ce projet.

Nos plus vifs remerciements s'adressent à notre encadrante académique, **Mme. Afifa Khalifa**, pour la qualité de son encadrement, ses orientations pertinentes, sa disponibilité constante et son suivi rigoureux tout au long de l'élaboration de ce rapport. Ses conseils avisés ont été déterminants pour garantir la rigueur scientifique de notre travail.

Notre sincère reconnaissance va également à notre encadrant professionnel, **M. Hamza Sessi**, pour sa confiance, son accompagnement technique et le partage généreux de son expertise. Nous remercions aussi l'ensemble de l'équipe de **MicroEdition** pour leur accueil chaleureux et la mise à disposition des ressources matérielles et logicielles indispensables à la concrétisation de ce projet.

Nous adressons nos remerciements respectueux aux membres du jury pour l'honneur qu'ils nous font en acceptant d'évaluer ce travail.

Nous exprimons également notre gratitude envers l'administration et le corps professoral de l'**ISSET de Mahdia**, en particulier le Département Technologies de l'Informatique, pour la qualité de la formation dispensée et pour nous avoir transmis les fondements académiques nécessaires à notre parcours.

Enfin, une pensée particulière va à nos familles, pour leur soutien inconditionnel et leurs sacrifices constants, ainsi qu'à nos amis et collègues pour leur encouragement et leur présence à nos côtés tout au long de cette expérience enrichissante.

TABLE DES MATIÈRES

Liste des Acronymes	xiii
Introduction Générale	1
I Cadre Général du Projet	3
Introduction	3
I Présentation de l'organisme d'accueil	3
I.1 Profil de l'entreprise et vision stratégique	3
I.2 Piliers technologiques centraux	4
I.3 Dynamique Organisationnelle et R&D	4
II Contexte général du projet	4
II.1 Agriculture intelligente et Agriculture 4.0	5
II.2 Hydroponie et production de fourrage	5
III Présentation du problème	6
III.1 Défis agricoles	6
III.2 Défis technologiques	7
IV Étude de l'existant	8
IV.1 Solutions existantes	8
IV.2 Limites des solutions existantes	9
V Solution Proposée	9

VI	Méthodologie de gestion de projet	11
VI.1	Présentation synthétique des méthodes retenues	12
VI.2	Hybridation au sein du modèle en V	13
	Conclusion	14
II	ÉTAT DE L'ART : APPROCHES INTELLIGENTES EN AGRICULTURE	16
	Introduction	16
I	Réseaux de neurones convolutifs (CNN)	17
I.1	Principe général	17
I.2	Évolution des architectures CNN	17
I.3	Limites des CNN pour le diagnostic agricole	18
II	Transformers et modèles vision-langage	19
II.1	Le mécanisme d'attention et les Transformers	19
II.2	Grands modèles de langage (LLM)	19
II.3	Modèles vision-langage (VLM)	19
III	Apprentissage adaptatif et dynamique	19
III.1	Apprentissage par ensembles	20
III.2	Apprentissage avec peu d'exemples (few-shot)	21
III.3	Apprentissage avec zéro exemple (zero-shot)	21
III.4	Sélection dynamique d'ensemble (DES)	21
III.5	Pertinence dans le contexte agricole	21
IV	Synthèse critique et positionnement	22
	Conclusion	23
III	ARCHITECTURE ET CONCEPTION	24
	Introduction	24
I	Vue d'Ensemble de l'Architecture Globale	25
I.1	Modèle de référence IoT à 4 couches	25
I.2	Évolution des architectures CNN	25
I.3	Limites des CNN pour le diagnostic agricole	26
II	Transformers et modèles vision-langage	27
II.1	Le mécanisme d'attention et les Transformers	27

II.2	Grands modèles de langage (LLM)	27
II.3	Modèles vision-langage (VLM)	27
III	Apprentissage adaptatif et dynamique	27
III.1	Apprentissage par ensembles	28
III.2	Apprentissage avec peu d'exemples (few-shot)	29
III.3	Apprentissage avec zéro exemple (zero-shot)	29
III.4	Sélection dynamique d'ensemble (DES)	29
III.5	Pertinence dans le contexte agricole	29
IV	Synthèse critique et positionnement	30
Conclusion		31

IV ÉTAT DE L'ART : APPROCHES INTELLIGENTES EN AGRICULTURE 32

Introduction		32
I	Réseaux de neurones convolutifs (CNN)	33
I.1	Principe général	33
I.2	Évolution des architectures CNN	33
I.3	Limites des CNN pour le diagnostic agricole	34
II	Transformers et modèles vision-langage	35
II.1	Le mécanisme d'attention et les Transformers	35
II.2	Grands modèles de langage (LLM)	35
II.3	Modèles vision-langage (VLM)	35
III	Apprentissage adaptatif et dynamique	35
III.1	Apprentissage par ensembles	36
III.2	Apprentissage avec peu d'exemples (few-shot)	37
III.3	Apprentissage avec zéro exemple (zero-shot)	37
III.4	Sélection dynamique d'ensemble (DES)	37
III.5	Pertinence dans le contexte agricole	37
IV	Synthèse critique et positionnement	38
Conclusion		39

V ÉTAT DE L'ART : APPROCHES INTELLIGENTES EN AGRICULTURE 40

Introduction		40
--------------	--	----

I	Réseaux de neurones convolutifs (CNN)	41
I.1	Principe général	41
I.2	Évolution des architectures CNN	41
I.3	Limites des CNN pour le diagnostic agricole	42
II	Transformers et modèles vision-langage	43
II.1	Le mécanisme d'attention et les Transformers	43
II.2	Grands modèles de langage (LLM)	43
II.3	Modèles vision-langage (VLM)	43
III	Apprentissage adaptatif et dynamique	43
III.1	Apprentissage par ensembles	44
III.2	Apprentissage avec peu d'exemples (few-shot)	45
III.3	Apprentissage avec zéro exemple (zero-shot)	45
III.4	Sélection dynamique d'ensemble (DES)	45
III.5	Pertinence dans le contexte agricole	45
IV	Synthèse critique et positionnement	46
	Conclusion	47

Bibliographie	48
----------------------	-----------

TABLE DES FIGURES

I.1	Le cycle CRISP-DM — six phases itératives pour les projets IA	12
I.2	Hybridation méthodologique : Kanban et CRISP-DM imbriqués dans le Cycle en V	14
II.1	Architecture d’InceptionV3 avec ses blocs parallèles.	17
II.2	Architecture de ResNet (connexions résiduelles).	18
II.3	Architecture de ConvNeXt.	18
II.4	Architecture fonctionnelle d’un système VQA.	20
II.5	Architecture de PaliGemma (SigLIP + Gemma).	20
III.1	Architecture d’InceptionV3 avec ses blocs parallèles.	25
III.2	Architecture de ResNet (connexions résiduelles).	26
III.3	Architecture de ConvNeXt.	26
III.4	Architecture fonctionnelle d’un système VQA.	28
III.5	Architecture de PaliGemma (SigLIP + Gemma).	28
IV.1	Architecture d’InceptionV3 avec ses blocs parallèles.	33
IV.2	Architecture de ResNet (connexions résiduelles).	34
IV.3	Architecture de ConvNeXt.	34
IV.4	Architecture fonctionnelle d’un système VQA.	36
IV.5	Architecture de PaliGemma (SigLIP + Gemma).	36
V.1	Architecture d’InceptionV3 avec ses blocs parallèles.	41

V.2	Architecture de ResNet (connexions résiduelles).	42
V.3	Architecture de ConvNeXt.	42
V.4	Architecture fonctionnelle d'un système VQA.	44
V.5	Architecture de PaliGemma (SigLIP + Gemma).	44

LISTE DES TABLEAUX

I.1	Analyse comparative des solutions hydroponiques existantes	10
I.2	Comparaison des méthodologies étudiées	13
I.3	Application des méthodologies aux différentes composantes du projet	14
II.1	Évolution des architectures CNN de référence	17
II.2	Évolution des modèles vision-langage	19
II.3	Synthèse comparative des paradigmes d'IA pour le diagnostic agricole	22
III.1	Évolution des architectures CNN de référence	25
III.2	Évolution des modèles vision-langage	27
III.3	Synthèse comparative des paradigmes d'IA pour le diagnostic agricole	30
IV.1	Évolution des architectures CNN de référence	33
IV.2	Évolution des modèles vision-langage	35
IV.3	Synthèse comparative des paradigmes d'IA pour le diagnostic agricole	38
V.1	Évolution des architectures CNN de référence	41
V.2	Évolution des modèles vision-langage	43
V.3	Synthèse comparative des paradigmes d'IA pour le diagnostic agricole	46

LISTE DES ACRONYMES

Acronyme	Signification
AI / IA	Artificial Intelligence / Intelligence Artificielle
API	Application Programming Interface
CNN	Convolutional Neural Network (Réseau de Neurones Convolutif)
CRISP-DM	Cross Industry Standard Process for Data Mining
DES	Dynamic Ensemble Selection
Edge AI	Intelligence Artificielle embarquée en périphérie réseau
F1-Score	Moyenne harmonique entre précision et rappel
HTTP/HTTPS	HyperText Transfer Protocol / Secure
IoT	Internet of Things (Internet des Objets)
JWT	JSON Web Token
LLM	Large Language Model
META-DES	Meta-learning for Dynamic Ensemble Selection
MQTT/MQTTS	Message Queuing Telemetry Transport / Secure
NLP	Natural Language Processing (Traitement du Langage Naturel)
ONNX	Open Neural Network Exchange
ORM	Object-Relational Mapping
RAG	Retrieval-Augmented Generation
REST	Representational State Transfer
SDK	Software Development Kit
SSL/TLS	Secure Sockets Layer / Transport Layer Security
UI/UX	User Interface / User Experience
UML	Unified Modeling Language
VLM	Vision Language Model
VQA	Visual Question Answering
WIP	Work In Progress
WS/WSS	WebSocket / WebSocket Secure

INTRODUCTION GÉNÉRALE

Le secteur agricole se trouve actuellement confronté à une convergence de défis mondiaux. Le changement climatique, la dégradation des écosystèmes et la pénurie croissante d'eau douce remettent en question les paradigmes agricoles traditionnels. Simultanément, la croissance de la population mondiale exige des rendements supérieurs sur des terres arables en diminution constante. Dans ce contexte, l'agriculture en environnement contrôlé, et plus particulièrement la production de fourrage hydroponique, émerge comme une alternative viable et efficiente. En substituant le sol par des solutions aquatiques recirculantes et riches en nutriments, les systèmes hydroponiques peuvent réduire la consommation d'eau agricole jusqu'à 90 % selon la littérature [?], tout en augmentant significativement la densité de production par mètre carré.

Cependant, la vulnérabilité intrinsèque des systèmes hydroponiques représente un défi d'ingénierie majeur. Dépourvus de la capacité de tamponnement naturel du sol, les environnements agricoles en intérieur exigent une précision microclimatique élevée. Même des fluctuations transitoires de l'humidité ambiante, de la température, des cycles photopériodiques ou de la conductivité électrique des nutriments peuvent déclencher une défaillance des cultures. De plus, les conditions denses et humides nécessaires à la croissance du fourrage favorisent la propagation fongique. Par conséquent, la supervision humaine manuelle se révèle insuffisante pour répondre aux exigences en temps réel de l'hydroponie moderne.

Ce projet de fin d'études, mené sous la supervision technique de **MicroEdition**, répond à ce dilemme à travers la conception architecturale et l'implémentation du système **HydroNova**. Cette plateforme constitue un écosystème agricole intelligent et autonome qui articule l'ingénierie matérielle et l'analyse logicielle. En faisant converger l'Internet des Objets (IoT) pour une régulation environnementale déterministe, et l'Intelligence Artificielle (Edge AI) pour des diagnostics biologiques proactifs, le système vise à réduire significativement l'intervention humaine dans la boucle de contrôle agricole.

La problématique centrale qui motive ce projet est la suivante : *Comment concevoir un système de contrôle IoT résilient et capable de fonctionner hors-ligne, augmenté par des réseaux de neurones convolutifs embarqués,*

afin d'automatiser, superviser et protéger biologiquement la production de fourrage hydroponique ?

Pour aborder cette question avec méthode, ce rapport est structuré en quatre chapitres détaillés :

- **Chapitre I** établit le contexte général du projet, présente l'organisme d'accueil (MicroEdition), effectue une analyse des solutions agricoles existantes, et définit l'architecture globale proposée ainsi que la méthodologie en Cycle en V adoptée.
- **Chapitre II** délimite les exigences fonctionnelles et non fonctionnelles du système, en formalisant les interactions entre les acteurs humains et matériels via les diagrammes UML (Unified Modeling Language).
- **Chapitre III** présente l'architecture globale du système, organisée en couches découplées, allant du réseau physique IoT (Edge) jusqu'aux couches de persistance Cloud.
- **Chapitre IV** couvre la réalisation technique du projet. Il détaille d'abord l'infrastructure matérielle et IoT (isolation électrique, Raspberry Pi, MQTT), puis l'intégration de l'Intelligence Artificielle embarquée (Edge AI) pour la détection des maladies. Il présente ensuite les interfaces applicatives développées (application mobile Flutter et tableau de bord web React), pour conclure sur la stratégie de déploiement Cloud (Docker, TimescaleDB, Spring Boot) et l'orchestration du backend.

CHAPITRE I

CADRE GÉNÉRAL DU PROJET

INTRODUCTION

Ce chapitre pose les fondements contextuels indispensables à la compréhension de la portée et des ambitions du HydroNova. Il s'ouvre sur la présentation de MicroEdition, l'organisme d'accueil, en détaillant son positionnement stratégique dans le domaine de l'intelligence embarquée et des écosystèmes IoT industriels. Nous procédons ensuite à une analyse critique du paysage technologique agricole actuel, en identifiant les lacunes structurelles des solutions disponibles sur le marché. Cette analyse nous permet de justifier la pertinence et la valeur ajoutée de notre système proposé. Le chapitre s'achève par la présentation de la méthodologie en Cycle en V, cadre d'ingénierie retenu pour structurer l'ensemble du processus de développement et de validation.

I PRÉSENTATION DE L'ORGANISME D'ACCUEIL

I.1 Profil de l'entreprise et vision stratégique

Fondée en 2025 et implantée au sein de la Pépinière d'Entreprises de Mahdia, MicroEdition est une entreprise technologique spécialisée dans les Technologies de l'Information et de la Communication. Sa vocation fondatrice est de combler le fossé entre la recherche académique avancée et les solutions industrielles directement déployables sur le terrain. L'intégration au sein de la pépinière offre à l'entreprise un écosystème collaboratif particulièrement stimulant : accès à une infrastructure technique adaptée au prototypage rapide, à un réseau interdisciplinaire de partenaires académiques et industriels, et à un environnement propice à

l'expérimentation à moindre risque. Cette proximité avec la recherche constitue un atout déterminant pour mener des projets à forte composante d'innovation, comme le HydroNova.

I.2 Piliers technologiques centraux

Le portefeuille opérationnel de MicroEdition s'articule autour de trois domaines d'expertise profondément interconnectés :

- **Ingénierie Logicielle** : L'entreprise conçoit des architectures logicielles modulaires et évolutives, ainsi que des interfaces utilisateurs multiplateformes et réactives. L'accent est mis sur la maintenabilité, la testabilité et la scalabilité des systèmes produits, afin de garantir une évolution fluide et durable des solutions développées.
- **Internet des Objets Industriel (IIoT)** : MicroEdition développe des réseaux embarqués résilients capables d'orchestrer des interactions matérielles autonomes. Ces réseaux s'appuient sur des protocoles de communication légers et sur des processus déterministes, garantissant la fiabilité des échanges même dans des environnements contraints en bande passante ou soumis à des coupures réseau fréquentes.
- **Intelligence Artificielle Embarquée (Edge AI)** : Le déploiement de modèles de Machine Learning directement sur des dispositifs à ressources limitées constitue la compétence différenciante de l'entreprise. Cette approche dite Edge-first élimine la latence et les risques d'indisponibilité inhérents à l'inférence basée sur le Cloud, tout en préservant la confidentialité des données produites localement.

I.3 Dynamique Organisationnelle et R&D

L'entreprise adopte une organisation hybride des processus de développement, adaptée à la nature des projets et à leurs contraintes spécifiques. Cette approche combine des cycles structurés de type prédictif pour les phases critiques, et des pratiques itératives inspirées des méthodes Agiles afin de favoriser la flexibilité, la réactivité et l'amélioration continue.

La cellule dédiée à la Recherche et Développement (R&D) est concentrée sur l'optimisation des contraintes de calcul des dispositifs "Edge" (à la périphérie du réseau). Cette compétence en R&D a été un facteur déterminant pour le système *HydroNova*, fournissant l'expertise requise pour exécuter des réseaux de neurones convolutifs directement sur un Raspberry Pi déployé localement.

II CONTEXTE GÉNÉRAL DU PROJET

L'agriculture connaît aujourd'hui une transformation profonde sous l'effet de la révolution numérique. Face à la croissance démographique mondiale, à la raréfaction des ressources naturelles et aux changements climatiques, les méthodes agricoles traditionnelles montrent certaines limites en matière de productivité, de

gestion des ressources et de résilience environnementale. Dans ce contexte, l'intégration des technologies numériques dans les systèmes agricoles apparaît comme une solution prometteuse pour améliorer l'efficacité des exploitations tout en garantissant une utilisation plus rationnelle des ressources.

Cette évolution a donné naissance au concept d'*Agriculture 4.0*, qui repose sur l'exploitation des technologies de l'Internet des Objets, de l'Intelligence Artificielle, du Cloud Computing et de l'analyse des données afin de moderniser les pratiques agricoles. L'objectif est de transformer les exploitations agricoles en systèmes intelligents capables de collecter, analyser et exploiter les données en temps réel pour optimiser la prise de décision et automatiser les processus de production.

II.1 Agriculture intelligente et Agriculture 4.0

L'Agriculture 4.0 représente l'application des technologies numériques avancées au secteur agricole. Elle vise à améliorer la productivité, réduire les coûts d'exploitation et limiter l'impact environnemental des activités agricoles grâce à une gestion intelligente des ressources.

L'un des piliers fondamentaux de cette transformation est l'Internet des Objets. Les capteurs connectés permettent de mesurer en temps réel différents paramètres tels que la température, l'humidité, la luminosité, le pH ou encore la qualité de l'eau. Ces données sont ensuite transmises vers des plateformes de supervision capables de surveiller l'état des cultures et de déclencher automatiquement des actions correctives lorsque cela est nécessaire.

Parallèlement, l'Intelligence Artificielle joue un rôle croissant dans l'automatisation des tâches agricoles. Grâce aux techniques d'apprentissage automatique et de vision par ordinateur, il devient possible de détecter précocement certaines maladies végétales, d'identifier des anomalies de croissance ou encore de fournir des recommandations adaptées aux agriculteurs. Ces technologies contribuent à améliorer la qualité de la production tout en réduisant les interventions manuelles.

Enfin, les systèmes de supervision connectée offrent une visibilité globale sur l'exploitation agricole. Les données collectées par les capteurs peuvent être visualisées à travers des applications mobiles ou des interfaces web, permettant aux utilisateurs de suivre l'évolution des paramètres environnementaux, de recevoir des alertes en temps réel et de piloter les équipements à distance. Cette approche favorise une gestion plus réactive, plus précise et davantage orientée vers l'optimisation des performances.

II.2 Hydroponie et production de fourrage

Parmi les approches innovantes adoptées dans le cadre de l'agriculture intelligente, l'hydroponie occupe une place importante. Cette technique consiste à cultiver les plantes sans sol, en utilisant une solution nutritive contrôlée qui fournit directement aux racines les éléments nécessaires à leur développement. Grâce à la maîtrise des conditions de culture, l'hydroponie permet d'obtenir une croissance rapide et régulière tout au long de l'année.

Dans le domaine de l'élevage, la production de fourrage hydroponique constitue une alternative intéressante aux méthodes conventionnelles. Les graines, généralement de l'orge, sont placées dans des plateaux de culture et irriguées de manière contrôlée pendant plusieurs jours jusqu'à obtenir un tapis végétal riche en nutriments destiné à l'alimentation animale. Ce procédé permet de produire du fourrage frais en continu, indépendamment des conditions climatiques extérieures.

L'hydroponie présente plusieurs avantages significatifs. Elle permet notamment une réduction importante de la consommation d'eau, une optimisation de l'espace de production, une diminution de la dépendance aux terres agricoles ainsi qu'une meilleure maîtrise des paramètres environnementaux. De plus, la production peut être réalisée de manière continue, garantissant une disponibilité régulière du fourrage pour les exploitations d'élevage.

Cependant, cette méthode présente également certaines contraintes. Les cultures hydroponiques nécessitent un contrôle permanent des paramètres environnementaux tels que la température, l'humidité, l'éclairage et les cycles d'irrigation. Une défaillance technique ou une variation importante de ces paramètres peut affecter rapidement la qualité de la production. Par ailleurs, les environnements humides favorisent le développement de maladies et de moisissures, rendant indispensable la mise en place de mécanismes de surveillance et de détection précoce.

C'est dans cette perspective que s'inscrit notre projet, dont l'objectif est de concevoir une serre hydroponique intelligente reposant sur l'intégration de technologies IoT, d'algorithmes d'Intelligence Artificielle et d'interfaces de supervision connectées afin d'automatiser la production, d'améliorer la surveillance des cultures et d'optimiser l'utilisation des ressources.

III PRÉSENTATION DU PROBLÈME

L'agriculture moderne fait face à de nombreux défis qui impactent directement la productivité des exploitations et la sécurité alimentaire. Dans le contexte tunisien, ces difficultés concernent aussi bien les aspects agricoles que les aspects technologiques. La mise en place d'un système hydroponique intelligent nécessite donc de répondre simultanément à ces deux catégories de contraintes.

III.1 Défis agricoles

Le secteur de l'élevage tunisien dépend fortement de la disponibilité d'un fourrage de qualité, produit de manière durable et économiquement viable. Toutefois, plusieurs facteurs limitent aujourd'hui les méthodes conventionnelles de production :

- **Stress hydrique croissant** : La raréfaction des ressources en eau et les périodes de sécheresse récurrentes rendent l'irrigation traditionnelle de plus en plus difficile et coûteuse.

- **Coût élevé de l'alimentation animale :** Les aliments concentrés importés représentent une part importante des dépenses des éleveurs et sont fortement influencés par les fluctuations du marché international.
- **Dépendance aux conditions climatiques :** Les rendements agricoles restent fortement liés aux variations saisonnières, ce qui complique la planification de la production fourragère.
- **Risques phytosanitaires :** Les environnements humides utilisés pour la culture hydroponique favorisent l'apparition de maladies, de moisissures et d'autres agents pathogènes pouvant compromettre la qualité du fourrage.
- **Besoin d'une production continue :** Les exploitations d'élevage nécessitent un approvisionnement régulier en fourrage tout au long de l'année, indépendamment des conditions climatiques extérieures.

III.2 Défis technologiques

Au-delà des contraintes agronomiques liées à la production hydroponique, la conception d'une plateforme intelligente intégrant l'Internet des Objets (IoT), l'Intelligence Artificielle (IA) et les technologies Web et Mobile soulève plusieurs défis technologiques majeurs. Ces défis concernent aussi bien l'acquisition des données, l'automatisation des processus que la prise de décision intelligente.

- **Collecte et traitement des données en temps réel :** Le système doit assurer une acquisition continue et fiable des données provenant des différents capteurs déployés dans l'environnement de culture. Les paramètres tels que la température, l'humidité, la luminosité, le niveau d'eau, le pH ou encore les cycles d'irrigation doivent être surveillés en permanence afin de garantir des conditions optimales de croissance. Cette collecte doit être accompagnée d'un traitement en temps réel permettant la détection rapide d'anomalies et la génération d'alertes pertinentes.
- **Automatisation intelligente des équipements :** La plateforme doit être capable de piloter automatiquement les différents actionneurs (pompes, électrovannes, systèmes d'éclairage, ventilateurs, etc.) en fonction des données collectées et des règles de contrôle définies. L'objectif est de réduire l'intervention humaine tout en assurant une gestion précise des ressources et un maintien optimal des conditions de culture.
- **Fonctionnement autonome et résilience du système :** Dans certaines zones agricoles, les interruptions de connexion Internet peuvent être fréquentes. Le système doit donc être conçu selon une architecture capable de continuer à fonctionner localement même en mode hors ligne. Cette autonomie implique la gestion locale des données critiques, l'exécution des règles d'automatisation et la synchronisation automatique avec les services distants dès le rétablissement de la connexion.
- **Détection intelligente des maladies et des anomalies :** L'identification précoce des maladies représente un enjeu majeur pour limiter les pertes de production. L'intégration de techniques de vision par ordinateur et de modèles d'apprentissage profond permet d'analyser automatiquement les images des cultures afin

de détecter les symptômes de maladies, les carences nutritionnelles ou les anomalies de croissance. Le défi consiste à obtenir des modèles à la fois précis, rapides et capables de fonctionner sur des ressources matérielles limitées.

- **Supervision et contrôle à distance :** Les exploitants doivent pouvoir accéder aux informations de leur installation depuis n'importe quel endroit via une interface web ou une application mobile. La plateforme doit fournir des tableaux de bord intuitifs, des visualisations en temps réel, des notifications d'alerte ainsi que des fonctionnalités de contrôle à distance garantissant une gestion efficace de l'exploitation.
- **Intégration et interopérabilité des technologies :** La solution repose sur l'interaction de plusieurs composants hétérogènes : capteurs IoT, microcontrôleurs, protocoles de communication, services backend, bases de données, modèles d'intelligence artificielle, applications web et mobiles. Assurer une communication fluide, sécurisée et performante entre ces différents éléments constitue un défi essentiel pour garantir la cohérence et la fiabilité du système global.
- **Sécurité et protection des données :** Les données collectées ainsi que les commandes de contrôle doivent être protégées contre les accès non autorisés. La mise en œuvre de mécanismes d'authentification, de chiffrement des communications et de gestion des droits d'accès est indispensable afin d'assurer la confidentialité, l'intégrité et la disponibilité des informations.
- **Scalabilité et évolutivité de la plateforme :** La solution doit être conçue de manière modulaire afin de faciliter l'ajout de nouveaux capteurs, de nouvelles fonctionnalités ou de nouveaux modèles d'intelligence artificielle. Cette évolutivité garantit l'adaptation de la plateforme aux besoins futurs des utilisateurs et aux évolutions technologiques.

Face à l'ensemble de ces défis, la problématique de ce projet consiste à concevoir et développer une plateforme hydroponique intelligente capable d'automatiser la production de fourrage, d'assurer une surveillance continue des cultures et de fournir des mécanismes avancés d'aide à la décision. Cette solution doit combiner efficacement les technologies IoT, l'Intelligence Artificielle, le Cloud Computing ainsi que les applications Web et Mobile afin d'améliorer la productivité, la qualité des cultures et l'efficacité opérationnelle des exploitations agricoles modernes.

IV ÉTUDE DE L'EXISTANT

IV.1 Solutions existantes

L'analyse des solutions disponibles dans le domaine de l'agriculture intelligente révèle plusieurs plateformes hydroponiques intégrant l'automatisation, les capteurs IoT et les technologies de contrôle environnemental. Les solutions suivantes représentent des références importantes dans le secteur des systèmes agricoles intelligents.



AgroSelf : Solution hydroponique intelligente destinée à l'automatisation de la culture végétale en environnement contrôlé. Le système intègre des mécanismes de surveillance des paramètres climatiques et nutritifs afin d'optimiser la croissance des plantes tout en réduisant la consommation d'eau et d'énergie.



GIY (Grow It Yourself) : Solution orientée agriculture domestique et urbaine permettant aux utilisateurs de cultiver des plantes de manière autonome. Elle propose une gestion simplifiée de l'irrigation, de l'éclairage et du suivi de croissance grâce à des technologies connectées adaptées aux petits espaces.



Biosolx : Plateforme spécialisée dans les systèmes agricoles intelligents utilisant des capteurs et des solutions IoT pour le contrôle automatisé de l'environnement de culture. Elle vise à améliorer la productivité agricole à travers l'analyse des données en temps réel et la gestion optimisée des ressources.

IV.2 Limites des solutions existantes

Malgré les fonctionnalités avancées offertes par les solutions étudiées, plusieurs limites demeurent présentes. La plupart des solutions reposent fortement sur des infrastructures centralisées ou des services distants, ce qui peut affecter leur autonomie et leur disponibilité. Par ailleurs, les capacités d'intelligence artificielle et de diagnostic automatisé restent souvent limitées ou absentes. Certaines solutions offrent également une faible adaptabilité aux contraintes des exploitations locales et nécessitent des coûts de déploiement ou de maintenance relativement élevés. Le tableau I.1 synthétise les principales limites identifiées à travers l'analyse comparative réalisée.

L'étude des solutions existantes montre qu'aucune d'entre elles ne répond simultanément aux exigences suivantes : autonomie hors ligne, intégration d'une intelligence artificielle avancée pour le diagnostic biologique, et accessibilité économique adaptée au contexte agricole tunisien.

Ainsi, ces limites justifient la nécessité de proposer une nouvelle architecture plus robuste, autonome et adaptée aux contraintes locales, constituant la base du système développé dans ce projet.

V SOLUTION PROPOSÉE

Pour répondre aux lacunes identifiées, nous proposons le **HydroNova** : une architecture de contrôle décentralisée et orientée *Edge-first*, conçue pour garantir une résilience opérationnelle totale en mode hors-ligne, tout en tirant parti des capacités d'analyse et de supervision offertes par le Cloud lorsque la connectivité est disponible.

Critères	AgroSelf	GIY (Grow It)	Biosolx
Dépendance Cloud	Forte dépendance à une infrastructure Cloud pour le contrôle.	Fonctionnement partiellement connecté.	Architecture centralisée dépendante du système distant.
Intelligence du système	Optimisation limitée aux paramètres environnementaux.	Assistance décisionnelle sans autonomie complète.	Automatisation industrielle sans intelligence contextuelle.
Vision et diagnostic	Absence de détection visuelle des maladies.	Observation manuelle par l'utilisateur.	Contrôle basé uniquement sur capteurs physiques.
Adaptabilité locale	Faible adaptation aux environnements ruraux.	Dépendance à la formation utilisateur.	Solution orientée industrie à grande échelle.
Coût et accessibilité	Coût élevé et maintenance complexe.	Coût modéré mais dépendance au support.	Solution industrielle difficilement accessible.
Assistance agronomique	Aucun accompagnement intelligent à l'agriculteur.	Interface passive sans conseil contextuel.	Pas d'assistance décisionnelle intégrée.

TABLE I.1 – Analyse comparative des solutions hydroponiques existantes

La solution s'articule autour de quatre axes technologiques complémentaires, avec une priorité stratégique accordée à l'intelligence embarquée :

- **L'Intelligence Artificielle Embarquée (Cœur de la détection sanitaire)** : Véritable pilier de la solution, ce module repose sur un réseau de neurones convolutifs (CNN) spécifiquement entraîné pour le diagnostic phytosanitaire du fourrage hydroponique. Déployé directement sur le Raspberry Pi sous forme d'un modèle quantifié en format ONNX (FP16), il effectue une inférence locale pour identifier en temps réel les marqueurs précoces de moisissures ou de stress fongique sur les images capturées par la caméra intégrée. Le traitement s'opère intégralement en local, garantissant une latence quasi nulle et une disponibilité totale indépendante de l'état du réseau. Cette sentinelle numérique assure une vigilance sanitaire permanente, capable d'isoler une menace biologique avant même qu'elle ne soit perceptible à l'œil nu.
- **Le Contrôleur Edge Autonome (Raspberry Pi)** : Ce nœud de calcul central exécute des services multi-processus optimisés assurant la régulation déterministe du microclimat : température, hygrométrie, pH, cycles d'irrigation et éclairage artificiel. Un mécanisme de surveillance matérielle de type Watchdog garantit le redémarrage automatique de tout service défaillant, préservant ainsi l'intégrité biologique de la culture contre tout arrêt non prévu du système.
- **Backend et Gestion de Données** : L'orchestration globale est assurée par une architecture robuste développée sous Spring Boot selon les principes de la Clean Architecture. Ce centre de commandement gère la réception asynchrone des flux téléométriques via le protocole sécurisé MQTTs, et ingère les

données dans InfluxDB, une base de données spécialisée dans le stockage et l'analyse efficace des séries temporelles. Cette couche analytique transforme les relevés bruts en historiques exploitables pour l'optimisation continue des rendements. Un chatbot agronomique basé sur une architecture RAG (Retrieval-Augmented Generation) avec Gemini complète ce dispositif en offrant un accompagnement intelligent et contextualisé à l'agriculteur.

- **Interfaces de Supervision :** L'interaction avec les utilisateurs est assurée par deux interfaces complémentaires. L'application mobile développée sous Flutter permet un pilotage nomade de la serre et la réception immédiate d'alertes critiques. Le tableau de bord d'administration React, associé à Grafana, offre aux gestionnaires une vue analytique haute résolution de l'ensemble du parc, avec configuration à distance et visualisation des séries temporelles.

En s'appuyant sur du matériel libre (Raspberry Pi) et des logiciels open-source, cette architecture réduit significativement les coûts d'acquisition et de maintenance, la rendant accessible aux exploitations de taille moyenne dans le contexte agricole tunisien. En combinant l'autonomie de l'Edge Computing aux capacités d'analyse du Cloud, cette solution vise à transformer la culture hydroponique en un processus sécurisé, intelligent et économiquement viable.

VI MÉTHODOLOGIE DE GESTION DE PROJET

La réussite d'un projet multidisciplinaire tel que *HydroNova* repose non seulement sur les choix technologiques, mais aussi sur l'adoption d'une méthodologie de gestion adaptée à la nature hybride du système. Ce projet combine en effet plusieurs dimensions complémentaires : des composants matériels (capteurs, actionneurs, Raspberry Pi, Arduino), des communications IoT temps réel (MQTT), un module d'intelligence artificielle (inférence locale CNN, assistant VLM cloud), un backend centralisé (Spring Boot, bases de données) et des interfaces utilisateurs multiples (Flutter, React).

Le projet *HydroNova* présente trois caractéristiques majeures qui justifient le recours à plusieurs méthodes :

1. **Intégration matérielle et logicielle :** Le système comporte une partie embarquée critique (contrôle des actionneurs, acquisition des capteurs) qui doit respecter des contraintes de temps réel et de fiabilité. Cette partie nécessite une validation formelle et une traçabilité rigoureuse.
2. **Développement logiciel distribué :** Le backend, l'application mobile et le tableau de bord web évoluent de manière continue. Ils appellent une gestion de flux flexible, capable de s'adapter aux changements sans bloquer l'intégration.
3. **Module d'intelligence artificielle :** La détection des maladies repose sur des données et des modèles d'apprentissage. Ce volet exige un cycle itératif spécifique (compréhension des données, préparation, modélisation, évaluation) différent du cycle classique du génie logiciel.

Aucune méthode unique ne couvre l'ensemble de ces exigences. Une approche méthodologique composite s'impose, où chaque sous-système est piloté par la méthode la mieux adaptée à son domaine, le tout étant orchestré par un **cadre global en V** qui garantit la traçabilité et la cohérence d'ensemble.

VI.1 Présentation synthétique des méthodes retenues

Modèle en V

Organisé en deux branches symétriques (spécification descendante, validation ascendante), il assure une traçabilité complète entre les exigences et les tests. Chaque phase de conception est associée à une phase de vérification de même niveau. Ce modèle est particulièrement adapté aux systèmes embarqués critiques et à l'intégration matérielle.

Kanban

Méthode de gestion visuelle du travail en flux continu. Elle repose sur un tableau divisé en colonnes (À faire, En cours, Terminé) et sur une limitation du travail en cours (WIP). Kanban permet une grande flexibilité pour les tâches de développement logiciel et s'intègre facilement à d'autres cadres.

CRISP-DM

Cadre de référence pour les projets d'intelligence artificielle. Il définit six phases itératives (compréhension du domaine, compréhension des données, préparation, modélisation, évaluation, déploiement). Ce cycle permet de revenir en arrière lorsque les résultats d'un modèle sont insuffisants.




FIGURE I.1 – Le cycle CRISP-DM — six phases itératives pour les projets IA

Ces trois approches présentent des profils complémentaires, comme le résume le tableau I.2.

Critère	Kanban	Cycle en V	CRISP-DM
Gestion des projets IoT	Bon	Excellent	Faible
Développement logiciel	Excellent	Bon	Faible
Gestion des systèmes embarqués	Moyen	Excellent	Faible
Traçabilité	Moyen	Excellent	Moyen
Flexibilité	Excellent	Faible	Bon
Validation formelle	Moyen	Excellent	Moyen
Projets IA	Bon	Moyen	Excellent

TABLE I.2 – Comparaison des méthodologies étudiées

VI.2 Hybridation au sein du modèle en V

Le cadre global du projet est le modèle en V. Il structure le rapport et le déroulement du projet, depuis l'analyse des besoins (chapitre III) jusqu'aux tests de validation (chapitre VI). Cependant, à l'intérieur de certaines phases du V, d'autres méthodes sont utilisées pour répondre aux spécificités des composants.

- **Phase de conception détaillée** : Pour le module IA, au lieu d'une spécification linéaire, nous exécutons un cycle CRISP-DM complet (compréhension des données, préparation, modélisation, évaluation). Ce cycle est itéré localement jusqu'à l'obtention d'un modèle satisfaisant. Une fois figé, le modèle entre dans la phase de réalisation du V.
- **Phase de réalisation et implémentation** : Le développement du backend, de l'application mobile et de l'interface web est géré par **Kanban** : un tableau numérique suit les tâches en flux continu, avec limitation du travail en cours (WIP). Les tâches sont découpées finement et intégrées dès qu'elles sont terminées, sans attendre la fin d'un sprint.
- **Branche ascendante (validation)** : Les tests d'intégration et les tests système respectent strictement le modèle en V, mais ils intègrent des boucles de rétroaction : par exemple, une anomalie détectée lors des tests d'intégration MQTT remonte vers la spécification des exigences pour affiner la QoS.

La figure I.2 illustre cette hybridation : le V global contient des « poches » méthodologiques où Kanban et CRISP-DM s'exécutent de manière itérative ou continue, tout en restant raccordées aux jalons du V.

L'hybridation n'est pas un empilement arbitraire : elle repose sur une analyse précise des forces et limites de chaque méthode (tableau I.2). Le modèle en V fournit le squelette — il fixe les jalons majeurs et assure la traçabilité ascendante/descendante. À l'intérieur de ce squelette, CRISP-DM apporte l'itération nécessaire à la fouille de données, tandis que Kanban apporte la fluidité pour le développement logiciel. Le tableau I.3 détaille l'affectation de chaque composant ou phase à la méthode principale, tout en précisant comment l'hybridation est mise en œuvre.




FIGURE I.2 – Hybridation méthodologique : Kanban et CRISP-DM imbriqués dans le Cycle en V

Phase / Activité	Méthodologie appliquée
Analyse des besoins (chapitre II)	Cycle en V (cadre)
Conception architecturale (chapitre III)	Cycle en V
Conception détaillée IA	CRISP-DM (itératif, intégré dans la phase de conception du V)
Développement Backend (Spring Boot)	Kanban
Développement Mobile (Flutter)	Kanban
Développement Interface Web (React)	Kanban
Système IoT et firmware (Arduino / Raspberry Pi)	Cycle en V
Intégration globale	Cycle en V
Validation et tests (chapitre V)	Cycle en V

TABLE I.3 – Application des méthodologies aux différentes composantes du projet

CONCLUSION

Ce premier chapitre a posé les bases du projet *HydroNova* en présentant son contexte institutionnel, son environnement technologique et la méthodologie de gestion retenue. L'analyse des solutions agricoles intelligentes existantes a révélé plusieurs limitations récurrentes, notamment une forte dépendance à la connectivité Internet et aux infrastructures Cloud, ce qui restreint leur déploiement dans les zones rurales peu desservies et expose les exploitants à des risques de latence ou de panne réseau.

Ces constats justifient la conception d'une architecture originale, résiliente et capable de fonctionner en mode hors ligne, où l'intelligence est répartie entre la périphérie (Edge AI sur Raspberry Pi) et le Cloud, et où les décisions critiques sont prises localement.

Par ailleurs, l'adoption d'une approche méthodologique hybride, combinant le Cycle en V pour la rigueur et la traçabilité, Kanban pour la fluidité du développement logiciel, et CRISP-DM pour l'itération propre à

l'intelligence artificielle. Cette hybridation offre un cadre de développement à la fois structuré, flexible et adapté aux spécificités d'un projet intégrant des composantes matérielles, logicielles et IA.

Les fondements du projet étant désormais établis, le chapitre suivant entre dans la phase d'étude approfondie. Il sera consacré à un état de l'art des architectures et méthodes intelligentes appliquées au domaine agricole. Nous y examinerons les techniques d'intelligence artificielle pour la détection de maladies végétales (CNN, Vision-Language Models, apprentissage par ensemble). Cette analyse permettra de positionner les choix technologiques d'*HydroNova* par rapport aux travaux antérieurs et de justifier les orientations retenues pour la suite du projet.

CHAPITRE II

ÉTAT DE L'ART : APPROCHES INTELLIGENTES EN AGRICULTURE

INTRODUCTION

L'agriculture moderne est confrontée à un double défi : augmenter les rendements tout en réduisant l'impact environnemental. En Tunisie, les pertes dues aux maladies végétales sont estimées entre 20 % et 40 % des récoltes [7]. L'absence d'outils de diagnostic précoce et accessible sur le terrain aggrave cette situation. L'intelligence artificielle, en particulier l'apprentissage profond appliqué à la vision par ordinateur et au traitement du langage naturel, ouvre des perspectives prometteuses.

Ce chapitre dresse un panorama critique des principales familles de modèles utilisables pour la détection des maladies végétales et l'assistance agricole. La première section présente les réseaux de neurones convolutifs (CNN), leur fonctionnement, leur évolution et leurs limites en conditions réelles. La deuxième section aborde les Transformers et les modèles vision-langage (VLM), qui intègrent des mécanismes d'attention et permettent l'interaction multimodale. La troisième section explore les techniques d'apprentissage adaptatif et dynamique : ensembles, few-shot, zero-shot et sélection dynamique, qui répondent aux contraintes d'évolutivité, de robustesse et d'hybridation Edge/Cloud. Une synthèse critique et le positionnement de l'architecture retenue pour le projet HydroNova concluent le chapitre.

I RÉSEAUX DE NEURONES CONVOLUTIFS (CNN)

I.1 Principe général

Les réseaux de neurones convolutifs (CNN) ont été conçus pour traiter efficacement des données structurées en grille, comme les images. Contrairement aux réseaux entièrement connectés, ils exploitent deux idées clés :

- **Convolution locales** : chaque neurone ne regarde qu'une petite région de l'image (son champ récepteur), ce qui réduit drastiquement le nombre de paramètres.
- **Partage des poids** : le même filtre (ou noyau) est appliqué sur toute l'image, ce qui rend le modèle invariant aux translations (un motif pathologique est reconnu où qu'il se trouve).

Une couche de convolution produit une *carte de caractéristiques* (*feature map*) qui met en évidence la présence de motifs élémentaires (contours, textures, taches). En empilant plusieurs couches, le modèle apprend des représentations de plus en plus abstraites : des arêtes dans les premières couches jusqu'aux structures sémantiques complexes (nécroses, lésions) dans les couches profondes. Des couches de *pooling* (sous-échantillonnage) introduisent une certaine invariance aux petites déformations.

I.2 Évolution des architectures CNN

Le tableau V.1 retrace les grandes étapes de l'évolution des CNN.

Architecture	Année	ImageNet Top-1	Innovation clé
AlexNet [11]	2012	63,3 %	ReLU, Dropout, parallélisation GPU.
VGGNet-16 [19]	2014	74,4 %	Empilement de petits filtres 3×3.
GoogLeNet [22]	2015	74,8 %	Modules Inception (convolutions multi-échelles).
ResNet-50 [9]	2016	76,1 %	Connexions résiduelles (<i>skip connections</i>).
InceptionV3 [23]	2016	77,9 %	Factorisation des noyaux.
MobileNetV2 [10]	2017	72,0 %	Convolution séparables en profondeur (embarqué).
EfficientNet-B4 [24]	2019	83,0 %	Mise à l'échelle coordonnée.
ConvNeXt-T [16]	2022	82,1 %	Modernisation inspirée des Transformers.

TABLE II.1 – Évolution des architectures CNN de référence

Les figures V.1, V.2 et V.3 illustrent respectivement InceptionV3, ResNet et ConvNeXt.




FIGURE II.1 – Architecture d'InceptionV3 avec ses blocs parallèles.




FIGURE II.2 – Architecture de ResNet (connexions résiduelles).




FIGURE II.3 – Architecture de ConvNeXt.

I.3 Limites des CNN pour le diagnostic agricole

Les CNNs ont montré leur efficacité pour la classification de maladies sur des jeux de données comme *PlantVillage*. Mohanty et al. [17] ont atteint une précision de 99,35 % pour 26 maladies sur 14 espèces. Too et al. [25] ont comparé plusieurs architectures (VGG, ResNet, DenseNet) et conclu que les réseaux avec connexions résiduelles ou denses offrent une meilleure stabilité.

Cependant, des limites importantes apparaissent dès que l'on sort du cadre contrôlé du laboratoire [2] :

1. **Manque d'explicabilité** : un CNN donne une probabilité, mais ne peut expliquer son raisonnement (par exemple, sur quels pixels il s'appuie).
2. **Information unidirectionnelle** : impossible d'intégrer des données contextuelles (historique de la culture, conditions climatiques) ou des questions de l'utilisateur.
3. **Fragilité aux variations réelles** : changement d'éclairage, flou de bougé, chevauchement de feuilles dégradent fortement les performances.

Ces lacunes motivent l'exploration d'architectures plus récentes, basées sur l'attention et la multimodalité.

II TRANSFORMERS ET MODÈLES VISION-LANGAGE

II.1 Le mécanisme d’attention et les Transformers

Introduit pour le traitement automatique des langues [26], le mécanisme d’**auto-attention** permet à chaque élément d’une séquence d’interagir directement avec tous les autres, contrairement aux CNN qui ont une vision locale. Cette capacité à capturer des dépendances à longue distance est particulièrement utile en agriculture pour relier des symptômes distants sur une même plante. Les Transformers sont gourmands en données et en calcul, mais des variantes comme le **Swin Transformer** [15] réduisent la complexité en limitant l’attention à des fenêtres locales.

II.2 Grands modèles de langage (LLM)

Les LLM (GPT, Gemini, etc.) sont des Transformers de type décodeur entraînés sur des masses de texte. Ils excellent en raisonnement et en génération de texte, mais sont **aveugles** : ils ne peuvent analyser une image. Pour le diagnostic agricole, ils doivent être combinés à un encodeur visuel.

II.3 Modèles vision-langage (VLM)

Un VLM associe trois composants : (1) un encodeur visuel (souvent un Vision Transformer), (2) un module d’alignement (projecteur ou Q-Former), (3) un LLM qui reçoit à la fois les tokens visuels et la question textuelle. Le tableau V.2 résume l’évolution récente.

Modèle	Année	Innovation
CLIP [18]	2021	Apprentissage contrastif image-texte.
BLIP-2 [12]	2023	Q-Former pour aligner vision et langage.
LLaVA [14]	2023	Projection linéaire + réglage par instructions.
InstructBLIP [5]	2023	Conditionnement du Q-Former par la question.
PaliGemma [3]	2024	Architecture unifiée SigLIP + Gemma 2B.

TABLE II.2 – Évolution des modèles vision-langage

La **question-réponse visuelle (VQA)** concrétise l’usage des VLM : l’utilisateur interroge le système en langage naturel, et le modèle répond en décrivant les symptômes (figure V.4). Les VQA offrent une interaction guidée et une explicabilité, mais souffrent encore d’hallucinations, d’une forte dépendance au cloud, et d’une sensibilité aux conditions de prise de vue.

III APPRENTISSAGE ADAPTATIF ET DYNAMIQUE

L’agriculture de précision impose des modèles capables de s’adapter à des conditions changeantes (nouvelles maladies, variétés de plantes, environnements) tout en restant robustes et explicables. Cette section explore les




FIGURE II.4 – Architecture fonctionnelle d'un système VQA.




FIGURE II.5 – Architecture de PaliGemma (SigLIP + Gemma).

techniques d'apprentissage qui permettent cette adaptabilité : les méthodes ensemblistes, l'apprentissage avec peu d'exemples (few-shot) et avec zéro exemple (zero-shot), ainsi que la sélection dynamique d'ensemble.

III.1 Apprentissage par ensembles

Les méthodes d'ensemble classiques, comme le *bagging* (forêts aléatoires) ou le *boosting* (AdaBoost, XGBoost), combinent plusieurs classifieurs pour réduire la variance et le biais. Appliquées aux réseaux de neurones, elles améliorent la robustesse : un ensemble de CNN peut surpasser n'importe lequel de ses membres pris isolément [6]. Cependant, ces approches restent **statiques** : la combinaison des modèles est figée une fois l'entraînement terminé. Or, un modèle peut exceller sur certaines régions de l'espace des caractéristiques et être médiocre sur d'autres.

III.2 Apprentissage avec peu d'exemples (few-shot)

En environnement agricole réel, il est fréquent de devoir identifier une nouvelle maladie ou une variété végétale pour laquelle on ne dispose que de très peu d'images (parfois moins d'une dizaine). L'**apprentissage avec peu d'exemples** (few-shot learning) répond à ce besoin. Le **méta-apprentissage** (*learning to learn*) en est une approche phare : l'algorithme MAML [8] apprend une initialisation des paramètres telle qu'une ou deux étapes de descente de gradient suffisent à adapter le modèle à une nouvelle tâche avec très peu de données. Cette capacité est cruciale pour un système comme HydroNova, qui doit pouvoir évoluer avec l'apparition de nouveaux pathogènes. D'autres approches comme *Prototypical Networks* [20] ou *Relation Networks* [21] sont également utilisées en agriculture [1].

III.3 Apprentissage avec zéro exemple (zero-shot)

Dans certains cas, aucune image de la nouvelle maladie n'est disponible au moment de l'entraînement. L'**apprentissage avec zéro exemple** (zero-shot learning) exploite des descriptions sémantiques (textuelles) des classes cibles. Les modèles vision-langage (VLM) comme CLIP [18] ou PaliGemma sont naturellement adaptés au zero-shot : ils comparent l'image à une description textuelle de la maladie (par exemple, « *taches brunes entourées d'un halo jaune sur feuilles de tomate* ») sans avoir jamais vu d'exemple visuel de cette pathologie. Cette approche est particulièrement pertinente pour les émergences phytosanitaires rapides [13].

III.4 Sélection dynamique d'ensemble (DES)

Pour pallier le caractère statique des ensembles classiques, la **sélection dynamique d'ensemble** (DES) choisit, pour chaque image à classer, les modèles les plus compétents localement. Le framework **META-DES** [4] procède ainsi :

1. Définition d'un voisinage de l'image cible (ses plus proches voisins dans un ensemble de validation).
2. Extraction de *méta-caractéristiques* pour chaque modèle candidat (précision locale, niveau de confiance, etc.).
3. Prédiction par un méta-classifieur de la compétence du modèle pour cette image.
4. Vote pondéré des seuls modèles jugés compétents.

Cette approche améliore significativement la précision et la robustesse, particulièrement utile en milieu agricole où les conditions d'acquisition (éclairage, angle, chevauchement) varient fortement. Des travaux récents l'appliquent au diagnostic de maladies des plantes [27].

III.5 Pertinence dans le contexte agricole

L'apprentissage adaptatif et dynamique répond à plusieurs contraintes du projet HydroNova :

- **Évolutivité** : l'apparition de nouvelles maladies ou de nouvelles variétés de plantes peut être prise en compte via le few-shot ou le zero-shot, sans réentraînement complet.
- **Robustesse aux variations** : la sélection dynamique d'ensemble permet de s'adapter localement à des conditions de terrain changeantes.
- **Hybridation Edge/Cloud** : le few-shot et le zero-shot peuvent être déployés en cloud (via VLM), tandis que la sélection dynamique d'ensemble peut être embarquée sur le Raspberry Pi pour une inférence rapide hors-ligne.

Ces techniques complètent ainsi naturellement l'architecture hybride proposée : le module embarqué repose sur un ensemble dynamique de CNN (DES), tandis que le module cloud exploite un VLM capable de zero-shot et de few-shot.

IV SYNTHÈSE CRITIQUE ET POSITIONNEMENT

Le tableau V.3 compare les différentes familles de modèles selon des critères opérationnels.

Approche	Apports	Limites	Offline	Explicabilité
CNN classiques	Efficaces, légers	Fragiles, boîtes noires	Oui	Faible
Ensembles de CNN	Robustesse	Complexité	Oui	Faible/Moyenne
Vision Transformers	Modélisation globale	Gourmands	Partiel	Moyenne
LLM	Raisonnement, texte	Aveugles	Non	Élevée
VLM / VQA	Multimodal, explicatif	Hallucinations, dépendance cloud	Non	Élevée
Few-shot / Zero-shot	Adaptabilité rapide	Nécessite un pré-entraînement adapté	Partiel	Moyenne/Élevée
DES (sélection dynamique)	Robustesse locale	Coût de calcul supplémentaire	Oui	Moyenne

TABLE II.3 – Synthèse comparative des paradigmes d'IA pour le diagnostic agricole

Aucune approche unique ne satisfait toutes les contraintes du projet HydroNova : besoin d'un fonctionnement hors-ligne (serres isolées), de robustesse aux conditions réelles, d'évolutivité face à de nouvelles maladies, et d'explicabilité pour l'utilisateur.

C'est pourquoi nous proposons une **architecture hybride** articulant deux branches complémentaires :

- Une branche **Edge** (embarquée sur Raspberry Pi) basée sur un ensemble dynamique de CNN (META-DES) pour une classification robuste, rapide et hors-ligne.
- Une branche **Cloud** exploitant un VLM (PaliGemma) pour l'assistance interactive, la génération d'explications, les cas ambigus, ainsi que l'adaptation en cas d'absence d'exemples.

Cette hybridation permet de concilier performance, résilience, adaptabilité et richesse sémantique.

CONCLUSION

Ce chapitre a présenté un panorama des principales architectures d'intelligence artificielle pour l'agriculture : CNN, Transformers, VLM, ainsi que les techniques d'apprentissage adaptatif et dynamique (ensembles, few-shot, zero-shot, sélection dynamique). L'analyse montre qu'aucun modèle isolé n'est suffisant, ce qui justifie l'approche hybride d'HydroNova. Le chapitre suivant détaille l'analyse des besoins et la spécification fonctionnelle du système.

CHAPITRE III

ARCHITECTURE ET CONCEPTION

INTRODUCTION

Ce chapitre présente l'architecture globale du système ainsi que les principaux choix de conception adoptés afin de répondre aux exigences fonctionnelles et non fonctionnelles du projet. Dans un contexte où le système intègre des objets connectés, des modules d'intelligence artificielle et des interfaces multi-utilisateurs, la définition d'une architecture claire et structurée constitue un enjeu essentiel pour garantir la cohérence, la maintenabilité et l'évolutivité de la solution.

Afin de maîtriser cette complexité, une approche architecturale en couches a été adoptée. Cette décomposition permet d'isoler les responsabilités de chaque composant du système, en distinguant les fonctions liées à l'acquisition des données, à la communication, au traitement centralisé et à l'interaction utilisateur. Chaque couche est conçue de manière indépendante tout en restant fortement interconnectée avec les autres, assurant ainsi une bonne interopérabilité et une meilleure robustesse globale.

Dans la suite de ce chapitre, l'architecture est analysée selon une décomposition en modules fonctionnels complémentaires. Le module IoT présente les équipements de la serre ainsi que les dispositifs embarqués assurant la collecte et le contrôle des données. Le module d'intelligence artificielle décrit les architectures mises en œuvre pour les modèles développés ainsi que les approches méthodologiques adoptées. Le module backend et communication détaille les mécanismes d'orchestration et d'échange des données entre les différents composants. Enfin, le module des interfaces utilisateur expose les environnements de supervision et d'interaction destinés aux différents profils d'utilisateurs.

Cette organisation progressive permet d'assurer une compréhension claire et structurée de l'ensemble de l'architecture du système.

I VUE D'ENSEMBLE DE L'ARCHITECTURE GLOBALE

I.1 Modèle de référence IoT à 4 couches

Les réseaux de neurones convolutifs (CNN) ont été conçus pour traiter efficacement des données structurées en grille, comme les images. Contrairement aux réseaux entièrement connectés, ils exploitent deux idées clés :

- **Convolution locales** : chaque neurone ne regarde qu'une petite région de l'image (son champ récepteur), ce qui réduit drastiquement le nombre de paramètres.
- **Partage des poids** : le même filtre (ou noyau) est appliqué sur toute l'image, ce qui rend le modèle invariant aux translations (un motif pathologique est reconnu où qu'il se trouve).

Une couche de convolution produit une *carte de caractéristiques* (*feature map*) qui met en évidence la présence de motifs élémentaires (contours, textures, taches). En empilant plusieurs couches, le modèle apprend des représentations de plus en plus abstraites : des arêtes dans les premières couches jusqu'aux structures sémantiques complexes (nécroses, lésions) dans les couches profondes. Des couches de *pooling* (sous-échantillonnage) introduisent une certaine invariance aux petites déformations.

I.2 Évolution des architectures CNN

Le tableau V.1 retrace les grandes étapes de l'évolution des CNN.

Architecture	Année	ImageNet Top-1	Innovation clé
AlexNet [11]	2012	63,3 %	ReLU, Dropout, parallélisation GPU.
VGGNet-16 [19]	2014	74,4 %	Empilement de petits filtres 3×3.
GoogLeNet [22]	2015	74,8 %	Modules Inception (convolutions multi-échelles).
ResNet-50 [9]	2016	76,1 %	Connexions résiduelles (<i>skip connections</i>).
InceptionV3 [23]	2016	77,9 %	Factorisation des noyaux.
MobileNetV2 [10]	2017	72,0 %	Convolution séparables en profondeur (embarqué).
EfficientNet-B4 [24]	2019	83,0 %	Mise à l'échelle coordonnée.
ConvNeXt-T [16]	2022	82,1 %	Modernisation inspirée des Transformers.

TABLE III.1 – Évolution des architectures CNN de référence

Les figures V.1, V.2 et V.3 illustrent respectivement InceptionV3, ResNet et ConvNeXt.




FIGURE III.1 – Architecture d'InceptionV3 avec ses blocs parallèles.




FIGURE III.2 – Architecture de ResNet (connexions résiduelles).




FIGURE III.3 – Architecture de ConvNeXt.

I.3 Limites des CNN pour le diagnostic agricole

Les CNNs ont montré leur efficacité pour la classification de maladies sur des jeux de données comme *PlantVillage*. Mohanty et al. [17] ont atteint une précision de 99,35 % pour 26 maladies sur 14 espèces. Too et al. [25] ont comparé plusieurs architectures (VGG, ResNet, DenseNet) et conclu que les réseaux avec connexions résiduelles ou denses offrent une meilleure stabilité.

Cependant, des limites importantes apparaissent dès que l'on sort du cadre contrôlé du laboratoire [2] :

1. **Manque d'explicabilité** : un CNN donne une probabilité, mais ne peut expliquer son raisonnement (par exemple, sur quels pixels il s'appuie).
2. **Information unidirectionnelle** : impossible d'intégrer des données contextuelles (historique de la culture, conditions climatiques) ou des questions de l'utilisateur.
3. **Fragilité aux variations réelles** : changement d'éclairage, flou de bougé, chevauchement de feuilles dégradent fortement les performances.

Ces lacunes motivent l'exploration d'architectures plus récentes, basées sur l'attention et la multimodalité.

II TRANSFORMERS ET MODÈLES VISION-LANGAGE

II.1 Le mécanisme d’attention et les Transformers

Introduit pour le traitement automatique des langues [26], le mécanisme d’**auto-attention** permet à chaque élément d’une séquence d’interagir directement avec tous les autres, contrairement aux CNN qui ont une vision locale. Cette capacité à capturer des dépendances à longue distance est particulièrement utile en agriculture pour relier des symptômes distants sur une même plante. Les Transformers sont gourmands en données et en calcul, mais des variantes comme le **Swin Transformer** [15] réduisent la complexité en limitant l’attention à des fenêtres locales.

II.2 Grands modèles de langage (LLM)

Les LLM (GPT, Gemini, etc.) sont des Transformers de type décodeur entraînés sur des masses de texte. Ils excellent en raisonnement et en génération de texte, mais sont **aveugles** : ils ne peuvent analyser une image. Pour le diagnostic agricole, ils doivent être combinés à un encodeur visuel.

II.3 Modèles vision-langage (VLM)

Un VLM associe trois composants : (1) un encodeur visuel (souvent un Vision Transformer), (2) un module d’alignement (projecteur ou Q-Former), (3) un LLM qui reçoit à la fois les tokens visuels et la question textuelle. Le tableau V.2 résume l’évolution récente.

Modèle	Année	Innovation
CLIP [18]	2021	Apprentissage contrastif image-texte.
BLIP-2 [12]	2023	Q-Former pour aligner vision et langage.
LLaVA [14]	2023	Projection linéaire + réglage par instructions.
InstructBLIP [5]	2023	Conditionnement du Q-Former par la question.
PaliGemma [3]	2024	Architecture unifiée SigLIP + Gemma 2B.

TABLE III.2 – Évolution des modèles vision-langage

La **question-réponse visuelle (VQA)** concrétise l’usage des VLM : l’utilisateur interroge le système en langage naturel, et le modèle répond en décrivant les symptômes (figure V.4). Les VQA offrent une interaction guidée et une explicabilité, mais souffrent encore d’hallucinations, d’une forte dépendance au cloud, et d’une sensibilité aux conditions de prise de vue.

III APPRENTISSAGE ADAPTATIF ET DYNAMIQUE

L’agriculture de précision impose des modèles capables de s’adapter à des conditions changeantes (nouvelles maladies, variétés de plantes, environnements) tout en restant robustes et explicables. Cette section explore les




FIGURE III.4 – Architecture fonctionnelle d'un système VQA.




FIGURE III.5 – Architecture de PaliGemma (SigLIP + Gemma).

techniques d'apprentissage qui permettent cette adaptabilité : les méthodes ensemblistes, l'apprentissage avec peu d'exemples (few-shot) et avec zéro exemple (zero-shot), ainsi que la sélection dynamique d'ensemble.

III.1 Apprentissage par ensembles

Les méthodes d'ensemble classiques, comme le *bagging* (forêts aléatoires) ou le *boosting* (AdaBoost, XGBoost), combinent plusieurs classifieurs pour réduire la variance et le biais. Appliquées aux réseaux de neurones, elles améliorent la robustesse : un ensemble de CNN peut surpasser n'importe lequel de ses membres pris isolément [6]. Cependant, ces approches restent **statiques** : la combinaison des modèles est figée une fois l'entraînement terminé. Or, un modèle peut exceller sur certaines régions de l'espace des caractéristiques et être médiocre sur d'autres.

III.2 Apprentissage avec peu d'exemples (few-shot)

En environnement agricole réel, il est fréquent de devoir identifier une nouvelle maladie ou une variété végétale pour laquelle on ne dispose que de très peu d'images (parfois moins d'une dizaine). L'**apprentissage avec peu d'exemples** (few-shot learning) répond à ce besoin. Le **méta-apprentissage** (*learning to learn*) en est une approche phare : l'algorithme MAML [8] apprend une initialisation des paramètres telle qu'une ou deux étapes de descente de gradient suffisent à adapter le modèle à une nouvelle tâche avec très peu de données. Cette capacité est cruciale pour un système comme HydroNova, qui doit pouvoir évoluer avec l'apparition de nouveaux pathogènes. D'autres approches comme *Prototypical Networks* [20] ou *Relation Networks* [21] sont également utilisées en agriculture [1].

III.3 Apprentissage avec zéro exemple (zero-shot)

Dans certains cas, aucune image de la nouvelle maladie n'est disponible au moment de l'entraînement. L'**apprentissage avec zéro exemple** (zero-shot learning) exploite des descriptions sémantiques (textuelles) des classes cibles. Les modèles vision-langage (VLM) comme CLIP [18] ou PaliGemma sont naturellement adaptés au zero-shot : ils comparent l'image à une description textuelle de la maladie (par exemple, « *taches brunes entourées d'un halo jaune sur feuilles de tomate* ») sans avoir jamais vu d'exemple visuel de cette pathologie. Cette approche est particulièrement pertinente pour les émergences phytosanitaires rapides [13].

III.4 Sélection dynamique d'ensemble (DES)

Pour pallier le caractère statique des ensembles classiques, la **sélection dynamique d'ensemble** (DES) choisit, pour chaque image à classer, les modèles les plus compétents localement. Le framework **META-DES** [4] procède ainsi :

1. Définition d'un voisinage de l'image cible (ses plus proches voisins dans un ensemble de validation).
2. Extraction de *méta-caractéristiques* pour chaque modèle candidat (précision locale, niveau de confiance, etc.).
3. Prédiction par un méta-classifieur de la compétence du modèle pour cette image.
4. Vote pondéré des seuls modèles jugés compétents.

Cette approche améliore significativement la précision et la robustesse, particulièrement utile en milieu agricole où les conditions d'acquisition (éclairage, angle, chevauchement) varient fortement. Des travaux récents l'appliquent au diagnostic de maladies des plantes [27].

III.5 Pertinence dans le contexte agricole

L'apprentissage adaptatif et dynamique répond à plusieurs contraintes du projet HydroNova :

- **Évolutivité** : l'apparition de nouvelles maladies ou de nouvelles variétés de plantes peut être prise en compte via le few-shot ou le zero-shot, sans réentraînement complet.
- **Robustesse aux variations** : la sélection dynamique d'ensemble permet de s'adapter localement à des conditions de terrain changeantes.
- **Hybridation Edge/Cloud** : le few-shot et le zero-shot peuvent être déployés en cloud (via VLM), tandis que la sélection dynamique d'ensemble peut être embarquée sur le Raspberry Pi pour une inférence rapide hors-ligne.

Ces techniques complètent ainsi naturellement l'architecture hybride proposée : le module embarqué repose sur un ensemble dynamique de CNN (DES), tandis que le module cloud exploite un VLM capable de zero-shot et de few-shot.

IV SYNTHÈSE CRITIQUE ET POSITIONNEMENT

Le tableau V.3 compare les différentes familles de modèles selon des critères opérationnels.

Approche	Apports	Limites	Offline	Explicabilité
CNN classiques	Efficaces, légers	Fragiles, boîtes noires	Oui	Faible
Ensembles de CNN	Robustesse	Complexité	Oui	Faible/Moyenne
Vision Transformers	Modélisation globale	Gourmands	Partiel	Moyenne
LLM	Raisonnement, texte	Aveugles	Non	Élevée
VLM / VQA	Multimodal, explicatif	Hallucinations, dépendance cloud	Non	Élevée
Few-shot / Zero-shot	Adaptabilité rapide	Nécessite un pré-entraînement adapté	Partiel	Moyenne/Élevée
DES (sélection dynamique)	Robustesse locale	Coût de calcul supplémentaire	Oui	Moyenne

TABLE III.3 – Synthèse comparative des paradigmes d'IA pour le diagnostic agricole

Aucune approche unique ne satisfait toutes les contraintes du projet HydroNova : besoin d'un fonctionnement hors-ligne (serres isolées), de robustesse aux conditions réelles, d'évolutivité face à de nouvelles maladies, et d'explicabilité pour l'utilisateur.

C'est pourquoi nous proposons une **architecture hybride** articulant deux branches complémentaires :

- Une branche **Edge** (embarquée sur Raspberry Pi) basée sur un ensemble dynamique de CNN (META-DES) pour une classification robuste, rapide et hors-ligne.
- Une branche **Cloud** exploitant un VLM (PaliGemma) pour l'assistance interactive, la génération d'explications, les cas ambigus, ainsi que l'adaptation en cas d'absence d'exemples.

Cette hybridation permet de concilier performance, résilience, adaptabilité et richesse sémantique.

CONCLUSION

Ce chapitre a présenté un panorama des principales architectures d'intelligence artificielle pour l'agriculture : CNN, Transformers, VLM, ainsi que les techniques d'apprentissage adaptatif et dynamique (ensembles, few-shot, zero-shot, sélection dynamique). L'analyse montre qu'aucun modèle isolé n'est suffisant, ce qui justifie l'approche hybride d'HydroNova. Le chapitre suivant détaille l'analyse des besoins et la spécification fonctionnelle du système.

CHAPITRE IV

ÉTAT DE L'ART : APPROCHES INTELLIGENTES EN AGRICULTURE

INTRODUCTION

L'agriculture moderne est confrontée à un double défi : augmenter les rendements tout en réduisant l'impact environnemental. En Tunisie, les pertes dues aux maladies végétales sont estimées entre 20 % et 40 % des récoltes [7]. L'absence d'outils de diagnostic précoce et accessible sur le terrain aggrave cette situation. L'intelligence artificielle, en particulier l'apprentissage profond appliqué à la vision par ordinateur et au traitement du langage naturel, ouvre des perspectives prometteuses.

Ce chapitre dresse un panorama critique des principales familles de modèles utilisables pour la détection des maladies végétales et l'assistance agricole. La première section présente les réseaux de neurones convolutifs (CNN), leur fonctionnement, leur évolution et leurs limites en conditions réelles. La deuxième section aborde les Transformers et les modèles vision-langage (VLM), qui intègrent des mécanismes d'attention et permettent l'interaction multimodale. La troisième section explore les techniques d'apprentissage adaptatif et dynamique : ensembles, few-shot, zero-shot et sélection dynamique, qui répondent aux contraintes d'évolutivité, de robustesse et d'hybridation Edge/Cloud. Une synthèse critique et le positionnement de l'architecture retenue pour le projet HydroNova concluent le chapitre.

I RÉSEAUX DE NEURONES CONVOLUTIFS (CNN)

I.1 Principe général

Les réseaux de neurones convolutifs (CNN) ont été conçus pour traiter efficacement des données structurées en grille, comme les images. Contrairement aux réseaux entièrement connectés, ils exploitent deux idées clés :

- **Convolution locales** : chaque neurone ne regarde qu'une petite région de l'image (son champ récepteur), ce qui réduit drastiquement le nombre de paramètres.
- **Partage des poids** : le même filtre (ou noyau) est appliqué sur toute l'image, ce qui rend le modèle invariant aux translations (un motif pathologique est reconnu où qu'il se trouve).

Une couche de convolution produit une *carte de caractéristiques* (*feature map*) qui met en évidence la présence de motifs élémentaires (contours, textures, taches). En empilant plusieurs couches, le modèle apprend des représentations de plus en plus abstraites : des arêtes dans les premières couches jusqu'aux structures sémantiques complexes (nécroses, lésions) dans les couches profondes. Des couches de *pooling* (sous-échantillonnage) introduisent une certaine invariance aux petites déformations.

I.2 Évolution des architectures CNN

Le tableau V.1 retrace les grandes étapes de l'évolution des CNN.

Architecture	Année	ImageNet Top-1	Innovation clé
AlexNet [11]	2012	63,3 %	ReLU, Dropout, parallélisation GPU.
VGGNet-16 [19]	2014	74,4 %	Empilement de petits filtres 3×3.
GoogLeNet [22]	2015	74,8 %	Modules Inception (convolutions multi-échelles).
ResNet-50 [9]	2016	76,1 %	Connexions résiduelles (<i>skip connections</i>).
InceptionV3 [23]	2016	77,9 %	Factorisation des noyaux.
MobileNetV2 [10]	2017	72,0 %	Convolution séparables en profondeur (embarqué).
EfficientNet-B4 [24]	2019	83,0 %	Mise à l'échelle coordonnée.
ConvNeXt-T [16]	2022	82,1 %	Modernisation inspirée des Transformers.

TABLE IV.1 – Évolution des architectures CNN de référence

Les figures V.1, V.2 et V.3 illustrent respectivement InceptionV3, ResNet et ConvNeXt.




FIGURE IV.1 – Architecture d'InceptionV3 avec ses blocs parallèles.




FIGURE IV.2 – Architecture de ResNet (connexions résiduelles).




FIGURE IV.3 – Architecture de ConvNeXt.

I.3 Limites des CNN pour le diagnostic agricole

Les CNNs ont montré leur efficacité pour la classification de maladies sur des jeux de données comme *PlantVillage*. Mohanty et al. [17] ont atteint une précision de 99,35 % pour 26 maladies sur 14 espèces. Too et al. [25] ont comparé plusieurs architectures (VGG, ResNet, DenseNet) et conclu que les réseaux avec connexions résiduelles ou denses offrent une meilleure stabilité.

Cependant, des limites importantes apparaissent dès que l'on sort du cadre contrôlé du laboratoire [2] :

1. **Manque d'explicabilité** : un CNN donne une probabilité, mais ne peut expliquer son raisonnement (par exemple, sur quels pixels il s'appuie).
2. **Information unidirectionnelle** : impossible d'intégrer des données contextuelles (historique de la culture, conditions climatiques) ou des questions de l'utilisateur.
3. **Fragilité aux variations réelles** : changement d'éclairage, flou de bougé, chevauchement de feuilles dégradent fortement les performances.

Ces lacunes motivent l'exploration d'architectures plus récentes, basées sur l'attention et la multimodalité.

II TRANSFORMERS ET MODÈLES VISION-LANGAGE

II.1 Le mécanisme d'attention et les Transformers

Introduit pour le traitement automatique des langues [26], le mécanisme d'**auto-attention** permet à chaque élément d'une séquence d'interagir directement avec tous les autres, contrairement aux CNN qui ont une vision locale. Cette capacité à capturer des dépendances à longue distance est particulièrement utile en agriculture pour relier des symptômes distants sur une même plante. Les Transformers sont gourmands en données et en calcul, mais des variantes comme le **Swin Transformer** [15] réduisent la complexité en limitant l'attention à des fenêtres locales.

II.2 Grands modèles de langage (LLM)

Les LLM (GPT, Gemini, etc.) sont des Transformers de type décodeur entraînés sur des masses de texte. Ils excellent en raisonnement et en génération de texte, mais sont **aveugles** : ils ne peuvent analyser une image. Pour le diagnostic agricole, ils doivent être combinés à un encodeur visuel.

II.3 Modèles vision-langage (VLM)

Un VLM associe trois composants : (1) un encodeur visuel (souvent un Vision Transformer), (2) un module d'alignement (projecteur ou Q-Former), (3) un LLM qui reçoit à la fois les tokens visuels et la question textuelle. Le tableau V.2 résume l'évolution récente.

Modèle	Année	Innovation
CLIP [18]	2021	Apprentissage contrastif image-texte.
BLIP-2 [12]	2023	Q-Former pour aligner vision et langage.
LLaVA [14]	2023	Projection linéaire + réglage par instructions.
InstructBLIP [5]	2023	Conditionnement du Q-Former par la question.
PaliGemma [3]	2024	Architecture unifiée SigLIP + Gemma 2B.

TABLE IV.2 – Évolution des modèles vision-langage

La **question-réponse visuelle (VQA)** concrétise l'usage des VLM : l'utilisateur interroge le système en langage naturel, et le modèle répond en décrivant les symptômes (figure V.4). Les VQA offrent une interaction guidée et une explicabilité, mais souffrent encore d'hallucinations, d'une forte dépendance au cloud, et d'une sensibilité aux conditions de prise de vue.

III APPRENTISSAGE ADAPTATIF ET DYNAMIQUE

L'agriculture de précision impose des modèles capables de s'adapter à des conditions changeantes (nouvelles maladies, variétés de plantes, environnements) tout en restant robustes et explicables. Cette section explore les




FIGURE IV.4 – Architecture fonctionnelle d'un système VQA.




FIGURE IV.5 – Architecture de PaliGemma (SigLIP + Gemma).

techniques d'apprentissage qui permettent cette adaptabilité : les méthodes ensemblistes, l'apprentissage avec peu d'exemples (few-shot) et avec zéro exemple (zero-shot), ainsi que la sélection dynamique d'ensemble.

III.1 Apprentissage par ensembles

Les méthodes d'ensemble classiques, comme le *bagging* (forêts aléatoires) ou le *boosting* (AdaBoost, XGBoost), combinent plusieurs classifieurs pour réduire la variance et le biais. Appliquées aux réseaux de neurones, elles améliorent la robustesse : un ensemble de CNN peut surpasser n'importe lequel de ses membres pris isolément [6]. Cependant, ces approches restent **statiques** : la combinaison des modèles est figée une fois l'entraînement terminé. Or, un modèle peut exceller sur certaines régions de l'espace des caractéristiques et être médiocre sur d'autres.

III.2 Apprentissage avec peu d'exemples (few-shot)

En environnement agricole réel, il est fréquent de devoir identifier une nouvelle maladie ou une variété végétale pour laquelle on ne dispose que de très peu d'images (parfois moins d'une dizaine). L'**apprentissage avec peu d'exemples** (few-shot learning) répond à ce besoin. Le **méta-apprentissage** (*learning to learn*) en est une approche phare : l'algorithme MAML [8] apprend une initialisation des paramètres telle qu'une ou deux étapes de descente de gradient suffisent à adapter le modèle à une nouvelle tâche avec très peu de données. Cette capacité est cruciale pour un système comme HydroNova, qui doit pouvoir évoluer avec l'apparition de nouveaux pathogènes. D'autres approches comme *Prototypical Networks* [20] ou *Relation Networks* [21] sont également utilisées en agriculture [1].

III.3 Apprentissage avec zéro exemple (zero-shot)

Dans certains cas, aucune image de la nouvelle maladie n'est disponible au moment de l'entraînement. L'**apprentissage avec zéro exemple** (zero-shot learning) exploite des descriptions sémantiques (textuelles) des classes cibles. Les modèles vision-langage (VLM) comme CLIP [18] ou PaliGemma sont naturellement adaptés au zero-shot : ils comparent l'image à une description textuelle de la maladie (par exemple, « *taches brunes entourées d'un halo jaune sur feuilles de tomate* ») sans avoir jamais vu d'exemple visuel de cette pathologie. Cette approche est particulièrement pertinente pour les émergences phytosanitaires rapides [13].

III.4 Sélection dynamique d'ensemble (DES)

Pour pallier le caractère statique des ensembles classiques, la **sélection dynamique d'ensemble** (DES) choisit, pour chaque image à classer, les modèles les plus compétents localement. Le framework **META-DES** [4] procède ainsi :

1. Définition d'un voisinage de l'image cible (ses plus proches voisins dans un ensemble de validation).
2. Extraction de *méta-caractéristiques* pour chaque modèle candidat (précision locale, niveau de confiance, etc.).
3. Prédiction par un méta-classifieur de la compétence du modèle pour cette image.
4. Vote pondéré des seuls modèles jugés compétents.

Cette approche améliore significativement la précision et la robustesse, particulièrement utile en milieu agricole où les conditions d'acquisition (éclairage, angle, chevauchement) varient fortement. Des travaux récents l'appliquent au diagnostic de maladies des plantes [27].

III.5 Pertinence dans le contexte agricole

L'apprentissage adaptatif et dynamique répond à plusieurs contraintes du projet HydroNova :

- **Évolutivité** : l'apparition de nouvelles maladies ou de nouvelles variétés de plantes peut être prise en compte via le few-shot ou le zero-shot, sans réentraînement complet.
- **Robustesse aux variations** : la sélection dynamique d'ensemble permet de s'adapter localement à des conditions de terrain changeantes.
- **Hybridation Edge/Cloud** : le few-shot et le zero-shot peuvent être déployés en cloud (via VLM), tandis que la sélection dynamique d'ensemble peut être embarquée sur le Raspberry Pi pour une inférence rapide hors-ligne.

Ces techniques complètent ainsi naturellement l'architecture hybride proposée : le module embarqué repose sur un ensemble dynamique de CNN (DES), tandis que le module cloud exploite un VLM capable de zero-shot et de few-shot.

IV SYNTHÈSE CRITIQUE ET POSITIONNEMENT

Le tableau V.3 compare les différentes familles de modèles selon des critères opérationnels.

Approche	Apports	Limites	Offline	Explicabilité
CNN classiques	Efficaces, légers	Fragiles, boîtes noires	Oui	Faible
Ensembles de CNN	Robustesse	Complexité	Oui	Faible/Moyenne
Vision Transformers	Modélisation globale	Gourmands	Partiel	Moyenne
LLM	Raisonnement, texte	Aveugles	Non	Élevée
VLM / VQA	Multimodal, explicatif	Hallucinations, dépendance cloud	Non	Élevée
Few-shot / Zero-shot	Adaptabilité rapide	Nécessite un pré-entraînement adapté	Partiel	Moyenne/Élevée
DES (sélection dynamique)	Robustesse locale	Coût de calcul supplémentaire	Oui	Moyenne

TABLE IV.3 – Synthèse comparative des paradigmes d'IA pour le diagnostic agricole

Aucune approche unique ne satisfait toutes les contraintes du projet HydroNova : besoin d'un fonctionnement hors-ligne (serres isolées), de robustesse aux conditions réelles, d'évolutivité face à de nouvelles maladies, et d'explicabilité pour l'utilisateur.

C'est pourquoi nous proposons une **architecture hybride** articulant deux branches complémentaires :

- Une branche **Edge** (embarquée sur Raspberry Pi) basée sur un ensemble dynamique de CNN (META-DES) pour une classification robuste, rapide et hors-ligne.
- Une branche **Cloud** exploitant un VLM (PaliGemma) pour l'assistance interactive, la génération d'explications, les cas ambigus, ainsi que l'adaptation en cas d'absence d'exemples.

Cette hybridation permet de concilier performance, résilience, adaptabilité et richesse sémantique.

CONCLUSION

Ce chapitre a présenté un panorama des principales architectures d'intelligence artificielle pour l'agriculture : CNN, Transformers, VLM, ainsi que les techniques d'apprentissage adaptatif et dynamique (ensembles, few-shot, zero-shot, sélection dynamique). L'analyse montre qu'aucun modèle isolé n'est suffisant, ce qui justifie l'approche hybride d'HydroNova. Le chapitre suivant détaille l'analyse des besoins et la spécification fonctionnelle du système.

CHAPITRE V

ÉTAT DE L'ART : APPROCHES INTELLIGENTES EN AGRICULTURE

INTRODUCTION

L'agriculture moderne est confrontée à un double défi : augmenter les rendements tout en réduisant l'impact environnemental. En Tunisie, les pertes dues aux maladies végétales sont estimées entre 20 % et 40 % des récoltes [7]. L'absence d'outils de diagnostic précoce et accessible sur le terrain aggrave cette situation. L'intelligence artificielle, en particulier l'apprentissage profond appliqué à la vision par ordinateur et au traitement du langage naturel, ouvre des perspectives prometteuses.

Ce chapitre dresse un panorama critique des principales familles de modèles utilisables pour la détection des maladies végétales et l'assistance agricole. La première section présente les réseaux de neurones convolutifs (CNN), leur fonctionnement, leur évolution et leurs limites en conditions réelles. La deuxième section aborde les Transformers et les modèles vision-langage (VLM), qui intègrent des mécanismes d'attention et permettent l'interaction multimodale. La troisième section explore les techniques d'apprentissage adaptatif et dynamique : ensembles, few-shot, zero-shot et sélection dynamique, qui répondent aux contraintes d'évolutivité, de robustesse et d'hybridation Edge/Cloud. Une synthèse critique et le positionnement de l'architecture retenue pour le projet HydroNova concluent le chapitre.

I RÉSEAUX DE NEURONES CONVOLUTIFS (CNN)

I.1 Principe général

Les réseaux de neurones convolutifs (CNN) ont été conçus pour traiter efficacement des données structurées en grille, comme les images. Contrairement aux réseaux entièrement connectés, ils exploitent deux idées clés :

- **Convolution locales** : chaque neurone ne regarde qu'une petite région de l'image (son champ récepteur), ce qui réduit drastiquement le nombre de paramètres.
- **Partage des poids** : le même filtre (ou noyau) est appliqué sur toute l'image, ce qui rend le modèle invariant aux translations (un motif pathologique est reconnu où qu'il se trouve).

Une couche de convolution produit une *carte de caractéristiques* (*feature map*) qui met en évidence la présence de motifs élémentaires (contours, textures, taches). En empilant plusieurs couches, le modèle apprend des représentations de plus en plus abstraites : des arêtes dans les premières couches jusqu'aux structures sémantiques complexes (nécroses, lésions) dans les couches profondes. Des couches de *pooling* (sous-échantillonnage) introduisent une certaine invariance aux petites déformations.

I.2 Évolution des architectures CNN

Le tableau V.1 retrace les grandes étapes de l'évolution des CNN.

Architecture	Année	ImageNet Top-1	Innovation clé
AlexNet [11]	2012	63,3 %	ReLU, Dropout, parallélisation GPU.
VGGNet-16 [19]	2014	74,4 %	Empilement de petits filtres 3×3.
GoogLeNet [22]	2015	74,8 %	Modules Inception (convolutions multi-échelles).
ResNet-50 [9]	2016	76,1 %	Connexions résiduelles (<i>skip connections</i>).
InceptionV3 [23]	2016	77,9 %	Factorisation des noyaux.
MobileNetV2 [10]	2017	72,0 %	Convolution séparables en profondeur (embarqué).
EfficientNet-B4 [24]	2019	83,0 %	Mise à l'échelle coordonnée.
ConvNeXt-T [16]	2022	82,1 %	Modernisation inspirée des Transformers.

TABLE V.1 – Évolution des architectures CNN de référence

Les figures V.1, V.2 et V.3 illustrent respectivement InceptionV3, ResNet et ConvNeXt.




FIGURE V.1 – Architecture d'InceptionV3 avec ses blocs parallèles.




FIGURE V.2 – Architecture de ResNet (connexions résiduelles).




FIGURE V.3 – Architecture de ConvNeXt.

I.3 Limites des CNN pour le diagnostic agricole

Les CNNs ont montré leur efficacité pour la classification de maladies sur des jeux de données comme *PlantVillage*. Mohanty et al. [17] ont atteint une précision de 99,35 % pour 26 maladies sur 14 espèces. Too et al. [25] ont comparé plusieurs architectures (VGG, ResNet, DenseNet) et conclu que les réseaux avec connexions résiduelles ou denses offrent une meilleure stabilité.

Cependant, des limites importantes apparaissent dès que l'on sort du cadre contrôlé du laboratoire [2] :

1. **Manque d'explicabilité** : un CNN donne une probabilité, mais ne peut expliquer son raisonnement (par exemple, sur quels pixels il s'appuie).
2. **Information unidirectionnelle** : impossible d'intégrer des données contextuelles (historique de la culture, conditions climatiques) ou des questions de l'utilisateur.
3. **Fragilité aux variations réelles** : changement d'éclairage, flou de bougé, chevauchement de feuilles dégradent fortement les performances.

Ces lacunes motivent l'exploration d'architectures plus récentes, basées sur l'attention et la multimodalité.

II TRANSFORMERS ET MODÈLES VISION-LANGAGE

II.1 Le mécanisme d’attention et les Transformers

Introduit pour le traitement automatique des langues [26], le mécanisme d’**auto-attention** permet à chaque élément d’une séquence d’interagir directement avec tous les autres, contrairement aux CNN qui ont une vision locale. Cette capacité à capturer des dépendances à longue distance est particulièrement utile en agriculture pour relier des symptômes distants sur une même plante. Les Transformers sont gourmands en données et en calcul, mais des variantes comme le **Swin Transformer** [15] réduisent la complexité en limitant l’attention à des fenêtres locales.

II.2 Grands modèles de langage (LLM)

Les LLM (GPT, Gemini, etc.) sont des Transformers de type décodeur entraînés sur des masses de texte. Ils excellent en raisonnement et en génération de texte, mais sont **aveugles** : ils ne peuvent analyser une image. Pour le diagnostic agricole, ils doivent être combinés à un encodeur visuel.

II.3 Modèles vision-langage (VLM)

Un VLM associe trois composants : (1) un encodeur visuel (souvent un Vision Transformer), (2) un module d’alignement (projecteur ou Q-Former), (3) un LLM qui reçoit à la fois les tokens visuels et la question textuelle. Le tableau V.2 résume l’évolution récente.

Modèle	Année	Innovation
CLIP [18]	2021	Apprentissage contrastif image-texte.
BLIP-2 [12]	2023	Q-Former pour aligner vision et langage.
LLaVA [14]	2023	Projection linéaire + réglage par instructions.
InstructBLIP [5]	2023	Conditionnement du Q-Former par la question.
PaliGemma [3]	2024	Architecture unifiée SigLIP + Gemma 2B.

TABLE V.2 – Évolution des modèles vision-langage

La **question-réponse visuelle (VQA)** concrétise l’usage des VLM : l’utilisateur interroge le système en langage naturel, et le modèle répond en décrivant les symptômes (figure V.4). Les VQA offrent une interaction guidée et une explicabilité, mais souffrent encore d’hallucinations, d’une forte dépendance au cloud, et d’une sensibilité aux conditions de prise de vue.

III APPRENTISSAGE ADAPTATIF ET DYNAMIQUE

L’agriculture de précision impose des modèles capables de s’adapter à des conditions changeantes (nouvelles maladies, variétés de plantes, environnements) tout en restant robustes et explicables. Cette section explore les




FIGURE V.4 – Architecture fonctionnelle d'un système VQA.




FIGURE V.5 – Architecture de PaliGemma (SigLIP + Gemma).

techniques d'apprentissage qui permettent cette adaptabilité : les méthodes ensemblistes, l'apprentissage avec peu d'exemples (few-shot) et avec zéro exemple (zero-shot), ainsi que la sélection dynamique d'ensemble.

III.1 Apprentissage par ensembles

Les méthodes d'ensemble classiques, comme le *bagging* (forêts aléatoires) ou le *boosting* (AdaBoost, XGBoost), combinent plusieurs classifieurs pour réduire la variance et le biais. Appliquées aux réseaux de neurones, elles améliorent la robustesse : un ensemble de CNN peut surpasser n'importe lequel de ses membres pris isolément [6]. Cependant, ces approches restent **statiques** : la combinaison des modèles est figée une fois l'entraînement terminé. Or, un modèle peut exceller sur certaines régions de l'espace des caractéristiques et être médiocre sur d'autres.

III.2 Apprentissage avec peu d'exemples (few-shot)

En environnement agricole réel, il est fréquent de devoir identifier une nouvelle maladie ou une variété végétale pour laquelle on ne dispose que de très peu d'images (parfois moins d'une dizaine). L'**apprentissage avec peu d'exemples** (few-shot learning) répond à ce besoin. Le **méta-apprentissage** (*learning to learn*) en est une approche phare : l'algorithme MAML [8] apprend une initialisation des paramètres telle qu'une ou deux étapes de descente de gradient suffisent à adapter le modèle à une nouvelle tâche avec très peu de données. Cette capacité est cruciale pour un système comme HydroNova, qui doit pouvoir évoluer avec l'apparition de nouveaux pathogènes. D'autres approches comme *Prototypical Networks* [20] ou *Relation Networks* [21] sont également utilisées en agriculture [1].

III.3 Apprentissage avec zéro exemple (zero-shot)

Dans certains cas, aucune image de la nouvelle maladie n'est disponible au moment de l'entraînement. L'**apprentissage avec zéro exemple** (zero-shot learning) exploite des descriptions sémantiques (textuelles) des classes cibles. Les modèles vision-langage (VLM) comme CLIP [18] ou PaliGemma sont naturellement adaptés au zero-shot : ils comparent l'image à une description textuelle de la maladie (par exemple, « *taches brunes entourées d'un halo jaune sur feuilles de tomate* ») sans avoir jamais vu d'exemple visuel de cette pathologie. Cette approche est particulièrement pertinente pour les émergences phytosanitaires rapides [13].

III.4 Sélection dynamique d'ensemble (DES)

Pour pallier le caractère statique des ensembles classiques, la **sélection dynamique d'ensemble** (DES) choisit, pour chaque image à classer, les modèles les plus compétents localement. Le framework **META-DES** [4] procède ainsi :

1. Définition d'un voisinage de l'image cible (ses plus proches voisins dans un ensemble de validation).
2. Extraction de *méta-caractéristiques* pour chaque modèle candidat (précision locale, niveau de confiance, etc.).
3. Prédiction par un méta-classifieur de la compétence du modèle pour cette image.
4. Vote pondéré des seuls modèles jugés compétents.

Cette approche améliore significativement la précision et la robustesse, particulièrement utile en milieu agricole où les conditions d'acquisition (éclairage, angle, chevauchement) varient fortement. Des travaux récents l'appliquent au diagnostic de maladies des plantes [27].

III.5 Pertinence dans le contexte agricole

L'apprentissage adaptatif et dynamique répond à plusieurs contraintes du projet HydroNova :

- **Évolutivité** : l'apparition de nouvelles maladies ou de nouvelles variétés de plantes peut être prise en compte via le few-shot ou le zero-shot, sans réentraînement complet.
- **Robustesse aux variations** : la sélection dynamique d'ensemble permet de s'adapter localement à des conditions de terrain changeantes.
- **Hybridation Edge/Cloud** : le few-shot et le zero-shot peuvent être déployés en cloud (via VLM), tandis que la sélection dynamique d'ensemble peut être embarquée sur le Raspberry Pi pour une inférence rapide hors-ligne.

Ces techniques complètent ainsi naturellement l'architecture hybride proposée : le module embarqué repose sur un ensemble dynamique de CNN (DES), tandis que le module cloud exploite un VLM capable de zero-shot et de few-shot.

IV SYNTHÈSE CRITIQUE ET POSITIONNEMENT

Le tableau V.3 compare les différentes familles de modèles selon des critères opérationnels.

Approche	Apports	Limites	Offline	Explicabilité
CNN classiques	Efficaces, légers	Fragiles, boîtes noires	Oui	Faible
Ensembles de CNN	Robustesse	Complexité	Oui	Faible/Moyenne
Vision Transformers	Modélisation globale	Gourmands	Partiel	Moyenne
LLM	Raisonnement, texte	Aveugles	Non	Élevée
VLM / VQA	Multimodal, explicatif	Hallucinations, dépendance cloud	Non	Élevée
Few-shot / Zero-shot	Adaptabilité rapide	Nécessite un pré-entraînement adapté	Partiel	Moyenne/Élevée
DES (sélection dynamique)	Robustesse locale	Coût de calcul supplémentaire	Oui	Moyenne

TABLE V.3 – Synthèse comparative des paradigmes d'IA pour le diagnostic agricole

Aucune approche unique ne satisfait toutes les contraintes du projet HydroNova : besoin d'un fonctionnement hors-ligne (serres isolées), de robustesse aux conditions réelles, d'évolutivité face à de nouvelles maladies, et d'explicabilité pour l'utilisateur.

C'est pourquoi nous proposons une **architecture hybride** articulant deux branches complémentaires :

- Une branche **Edge** (embarquée sur Raspberry Pi) basée sur un ensemble dynamique de CNN (META-DES) pour une classification robuste, rapide et hors-ligne.
- Une branche **Cloud** exploitant un VLM (PaliGemma) pour l'assistance interactive, la génération d'explications, les cas ambigus, ainsi que l'adaptation en cas d'absence d'exemples.

Cette hybridation permet de concilier performance, résilience, adaptabilité et richesse sémantique.

CONCLUSION

Ce chapitre a présenté un panorama des principales architectures d'intelligence artificielle pour l'agriculture : CNN, Transformers, VLM, ainsi que les techniques d'apprentissage adaptatif et dynamique (ensembles, few-shot, zero-shot, sélection dynamique). L'analyse montre qu'aucun modèle isolé n'est suffisant, ce qui justifie l'approche hybride d'HydroNova. Le chapitre suivant détaille l'analyse des besoins et la spécification fonctionnelle du système.

BIBLIOGRAPHIE

- [1] Andrea Argüello et al. Few-shot learning for plant disease recognition : A review. *Agronomy*, 2020.
- [2] Jayme Garcia Arnal Barbedo. Factors influencing the use of deep learning for plant disease recognition. *Biosystems Engineering*, 172 :84–91, 2018.
- [3] Lucas Beyer, Andreas Steiner, André Susano Pinto, Alexander Kolesnikov, Xiaohua Wang, et al. Paligemma : A versatile 3b vlm for transfer. In *arXiv preprint arXiv :2407.07726*, 2024.
- [4] Rafael M O Cruz, Robert Sabourin, and George D C Cavalcanti. Meta-des : A dynamic ensemble selection framework using meta-learning. *Pattern Recognition*, 80 :94–111, 2018.
- [5] Wenliang Dai, Junnan Li, Dongxu Li, Anthony Meng Huat Tiong, Jun Zhao, Weisheng Wang, Boyang Li, Pascale Fung, and Steven Hoi. Instructblip : Towards general-purpose vision-language models with instruction tuning. In *Advances in Neural Information Processing Systems*, 2023.
- [6] Thomas G Dietterich. Ensemble methods in machine learning. *Multiple Classifier Systems*, pages 1–15, 2000.
- [7] FAO. The state of food and agriculture 2021. Technical report, Food and Agriculture Organization of the United Nations, 2021.
- [8] Chelsea Finn, Pieter Abbeel, and Sergey Levine. Model-agnostic meta-learning for fast adaptation of deep networks. In *International Conference on Machine Learning (ICML)*, 2017.
- [9] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.
- [10] Andrew G Howard, Menglong Zhu, Bo Chen, Dmitry Kalenichenko, Weijun Wang, Tobias Weyand, Marco Andreetto, and Hartwig Adam. Mobilenets : Efficient convolutional neural networks for mobile vision applications. In *arXiv preprint arXiv :1704.04861*, 2017.
- [11] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E Hinton. Imagenet classification with deep convolutional neural networks. In *Advances in Neural Information Processing Systems*, volume 25, 2012.

-
- [12] Junnan Li, Dongxu Li, Silvio Savarese, and Steven Hoi. Blip-2 : Bootstrapping language-image pre-training with frozen image encoders and large language models. In *International Conference on Machine Learning (ICML)*, 2023.
 - [13] Y Li, H Wang, Y Duan, et al. Zero-shot learning for plant disease recognition. In *IEEE International Conference on Multimedia and Expo (ICME)*, 2020.
 - [14] Haotian Liu, Chunyuan Li, Qingyang Wu, and Yong Jae Lee. Visual instruction tuning. In *Advances in Neural Information Processing Systems*, 2023.
 - [15] Ze Liu, Yutong Lin, Yue Cao, Han Hu, Yixuan Wei, Zheng Zhang, Stephen Lin, and Baining Guo. Swin transformer : Hierarchical vision transformer using shifted windows. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, 2021.
 - [16] Zhuang Liu, Hanzi Mao, Chao-Yuan Wu, Christoph Feichtenhofer, Trevor Darrell, and Saining Xie. A convnet for the 2020s. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, 2022.
 - [17] Sharada P Mohanty, David P Hughes, and Marcel Salathé. Using deep learning for image-based plant disease detection. *Frontiers in Plant Science*, 7 :1419, 2016.
 - [18] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, et al. Learning transferable visual models from natural language supervision. In *International Conference on Machine Learning (ICML)*, 2021.
 - [19] Karen Simonyan and Andrew Zisserman. Very deep convolutional networks for large-scale image recognition. In *International Conference on Learning Representations (ICLR)*, 2015.
 - [20] Jake Snell, Kevin Swersky, and Richard Zemel. Prototypical networks for few-shot learning. In *Advances in Neural Information Processing Systems*, volume 30, 2017.
 - [21] Flood Sung, Yongxin Yang, Li Zhang, Tao Xiang, Philip H S Torr, and Timothy M Hospedales. Learning to compare : Relation network for few-shot learning. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018.
 - [22] Christian Szegedy, Wei Liu, Yangqing Jia, Pierre Sermanet, Scott Reed, Dragomir Anguelov, Dumitru Erhan, Vincent Vanhoucke, and Andrew Rabinovich. Going deeper with convolutions. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2015.
 - [23] Christian Szegedy, Vincent Vanhoucke, Sergey Ioffe, Jon Shlens, and Zbigniew Wojna. Rethinking the inception architecture for computer vision. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.
 - [24] Mingxing Tan and Quoc V Le. Efficientnet : Rethinking model scaling for convolutional neural networks. In *International Conference on Machine Learning (ICML)*, 2019.
 - [25] Edna Chebet Too, Li Yujian, Samuel Njuki, and Liu Yingchun. A comparative study of fine-tuning deep learning models for plant disease identification. *Computers and Electronics in Agriculture*,

161 :272–279, 2019.

- [26] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Lukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30, 2017.
- [27] X Zhang, Y Qiao, F Meng, et al. Dynamic ensemble selection for plant disease recognition. *Computers and Electronics in Agriculture*, 2020.